CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA
UNIDADE DE PÓS-GRADUAÇÃO, EXTENSÃO E PESQUISA

PROGRAMA DE MESTRADO PROFISSIONAL EM GESTÃO E TECNOLOGIA EM SISTEMAS PRODUTIVOS

PROJETO DA PESQUISA EXPERIMENTAL

Gestão Eficiente de Restaurantes Universitários: Análise Exploratória de Dados e Simulação Probabilística para Redução de Desperdícios

Projeto da Pesquisa Experimental da disciplina de MQA.

Michel Silva de Souza

Julyana Nazario Alves

Vinicius de Oliveira Querencia

São Paulo

11/2025

SUMÁRIO

1. INTRODUÇÃO 4
2. OBJETIVOS 5
    2.1 Objetivo geral 5
    2.2 Objetivos específicos 5
3. REFERENCIAL TEÓRICO E TRABALHOS CORRELATOS 6
4. MÉTODO DE PESQUISA 6
    4.1 Tipo e Desenho da Pesquisa 7
    4.2 População e Amostra 7
    4.3 Material e Ambiente do Experimento 8
    4.4 Procedimentos de Coleta e Tratamento de Dados 8
    4.5 Análise de Dados 15
    4.6 Aspectos Éticos e Riscos Associados 15
5 CRONOGRAMA 4
6. ATIVIDADES REALIZADAS 4
    6.1 Coleta e Preparação da Base de Dados 4
    6.2 Análise Exploratória e Modelagem Empírica 4
    6.3 Estruturação e Execução do Modelo de Simulação 4
    6.4 Coleta e Análise dos Resultados da Simulação 5
7. RESULTADOS 5
8. CONCLUSÕES 10
    8.1. Limitações, Riscos Metodológicos e Vieses Potenciais 10
        8.1.1 Limitações Gerais *10*
        8.1.2 Riscos Metodológicos e de Interpretação *11*
    8.2. Implicações Práticas e Próximos Passos 11
REFERÊNCIAS BIBLIOGRÁFICAS 13

1. INTRODUÇÃO

A gestão da demanda em refeitórios institucionais, particularmente em restaurantes universitários, configura-se como um desafio operacional e estratégico de alta complexidade. Esses ambientes servem diariamente a uma população vasta e diversificada, composta por estudantes, docentes e servidores, frequentemente atuando como a principal fonte de alimentação acessível para estudantes em situação de vulnerabilidade socioeconômica (PAYNE-STURGES et al., 2017; LOOFBOURROW, 2023). A garantia de refeições regulares e nutricionalmente adequadas transcende o escopo assistencial, tornando-se um pilar fundamental das políticas de equidade e inclusão no ensino superior.

Contudo, o planejamento da produção nesses refeitórios é um processo complexo e muitas vezes reativo. A volatilidade das reservas, caracterizada por "*no-shows*" (estudantes que reservam e não comparecem) e "*walk-ins*" (usuários que consomem sem reserva prévia), gera dois problemas centrais: o desperdício de alimentos devido à superprodução e a insatisfação dos usuários em caso de escassez. Do ponto de vista institucional, o desperdício representa perda econômica e impacto ambiental, onerando a sustentabilidade financeira das universidades (CBORD, 2025; REFED, 2016), enquanto a escassez pode comprometer a permanência estudantil. Falhas na previsão de demanda e na coordenação de processos logísticos são apontadas como principais fontes de ineficiência em sistemas de refeições coletivas (AKKERMAN, 2024).

A resolução desse desafio exige abordagens que lidem com a incerteza da demanda e a ineficiência operacional. Para aprimorar este cenário, será explorada a simulação probabilística, amplamente aplicada em contextos de planejamento estratégico para explorar cenários sob incerteza e quantificar riscos (SHEEL, 1995; CHOI, 2022). A adoção conjunta da análise exploratória de dados e da simulação probabilística permite projetar os impactos de diferentes políticas de produção, oferecendo subsídios para decisões baseadas em evidências.

A hipótese central deste estudo é que a implementação integrada de análise exploratória de séries temporais para identificação de padrões de demanda e simulação probabilística para modelagem de cenários sob incerteza pode resultar

em uma redução percentual significativa do desperdício de alimentos (superior a 10%) em refeitórios institucionais, em comparação com os métodos de planejamento reativos atuais.

2. OBJETIVOS

2.1 Objetivo geral

Compreender, mapear e simular os processos de reservas e consumo, identificando gargalos e propondo melhorias operacionais para refeitórios institucionais sob diferentes cenários de incerteza, integrando análise exploratória de dados e simulação de cenários, visando reduzir desperdícios de alimentos, otimizar a eficiência operacional e promover a sustentabilidade.

2.2 Objetivos específicos

- Analisar e modelar o padrão de demanda histórica de refeições em refeitórios institucionais, identificando e quantificando sazonalidades (ex: semanal) e tendências, utilizando técnicas de análise exploratória de dados e decomposição de séries temporais para compreender o impacto das variáveis e os dias de maior/menor consumo.
- Mapear os fluxos reais do processo de reservas e consumo de refeições, bem como as interações com a aquisição de insumos identificando desvios (ex.: reservas feitas, mas não consumidas; consumo sem reserva), gargalos e padrões de "no-show" em relação aos fluxos prescritos.
- Desenvolver um modelo de simulação para testar cenários alternativos de planejamento de produção e políticas de gestão de reservas (ex: redução do tempo entre reserva e preparo, ajuste da produção com base em atributos de cardápio, e implementação de políticas de incentivo/penalidade para "no-show"), avaliando seu impacto na redução do desperdício e na eficiência operacional.
- Propor diretrizes e um plano de ação detalhado para a implementação das melhorias identificadas na gestão da cadeia de suprimentos do refeitório, com foco na escalabilidade e reprodutibilidade.

3. REFERENCIAL TEÓRICO E TRABALHOS CORRELATOS

A literatura sobre gestão de serviços de alimentação e previsão de demanda tem evoluído significativamente, incorporando métodos quantitativos e computacionais para otimização de processos. A simulação probabilística, em particular a Simulação de Monte Carlo, tem sido amplamente utilizada para modelar sistemas complexos sob incerteza, permitindo a avaliação de riscos e a projeção de resultados em diferentes cenários (SHEEL, 1995; CHOI, 2022). No contexto de restaurantes, a aplicação dessas técnicas visa aprimorar a tomada de decisão, especialmente no que tange à gestão de estoques e à produção, minimizando perdas e maximizando a satisfação do cliente.

Estudos recentes têm explorado o uso de Machine Learning e Inteligência Artificial para aprimorar a previsão de demanda em diversos setores, incluindo o alimentício (CHAUDHARI et al., 2025; OLAWALE et al., 2025). A capacidade de processar grandes volumes de dados e identificar padrões complexos torna essas abordagens valiosas para lidar com a variabilidade inerente à demanda de refeições. A engenharia de *features*, que envolve a criação de novas variáveis a partir de dados existentes, é um componente crucial para o sucesso desses modelos, permitindo capturar sazonalidades, tendências e o impacto de eventos externos (RAJENDRAN et al., 2025).

A problemática do desperdício de alimentos em instituições de ensino superior é um tema de crescente preocupação, com implicações econômicas, sociais e ambientais (CBORD, 2025; REFED, 2016). A ineficiência na gestão da demanda, exacerbada por fenômenos como "*no-show*" e "*walk-in*", contribui significativamente para esse problema (AKKERMAN, 2024). A integração de análises preditivas e simulações oferece um caminho promissor para mitigar esses desafios, permitindo que as instituições desenvolvam políticas de produção mais eficazes e sustentáveis.

4. MÉTODO DE PESQUISA

A presente pesquisa adota uma abordagem quantitativa, com desenho descritivo e exploratório, focando na análise exploratória de dados e na simulação probabilística para otimização da gestão de refeições em refeitórios universitários.

4.1 Tipo e Desenho da Pesquisa

A pesquisa é de natureza quantitativa. O estudo adota um desenho descritivo e exploratório. A fase descritiva busca caracterizar os padrões históricos de consumo e reservas de refeições no refeitório institucional, enquanto a fase exploratória, por sua vez, utiliza a simulação probabilística para testar cenários alternativos de planejamento e políticas operacionais, oferecendo evidências empíricas para a tomada de decisão gerencial. A Tabela 1 resume as fases da análise, seus procedimentos e os objetivos específicos correspondentes.

Tabela 1 - Fases da Análise e Relação com os Objetivos

Fases da análise	**Procedimento**	**Objetivo (Conforme item 2.2)**
Modelagem da Demanda (Objetivo Específico 1 e 2)	Modelos Preditivos e *Feature Selection*: Desenvolver modelos preditivos (*Treatment*) (ex: SARIMA, Regressão Linear Múltipla) utilizando a Sazonalidade de 5 dias e as *features* de cardápio e clima como Variáveis Independentes (*X*). O foco é maximizar a precisão (R^2, *MAPE*) da previsão de demanda (*Y*) para a próxima semana (*df_predicao*).	Refinamento da modelagem do padrão de demanda.
Simulação (Objetivo Específico 3 e 4)	Construção do Modelo de Simulação com as distribuições probabilísticas (extraídas da EDA) para modelar o refeitório. Teste de Cenários (*Treatments*): Comparar o cenário atual (A) com políticas de produção alternativas (B, C...), manipulando variáveis como estoque de segurança ou tempo de *lead-time* para suprimentos.	Desenvolver e validar o Modelo de Gestão Otimizada.
Validação e Conclusão (Objetivo Específico 4 e 5)	Cálculo de Ganhos: Quantificar o desperdício esperado e custos nos cenários simulados. Proposição de Diretrizes: Elaborar o plano de ação detalhado para a implementação das políticas ótimas.	Quantificar os ganhos esperados para a redução de desperdício.

Fonte: Elaborado pelos autores.

4.2 População e Amostra

A população-alvo compreende o conjunto de usuários do refeitório institucional (discentes) e os registros administrativos correspondentes às operações

de reserva e consumo de refeições. A amostra de dados é constituída por registros históricos extraídos do sistema de controle do refeitório, abrangendo um período de 6 meses de operação contínua, o que permite identificar padrões sazonais semanais e mensais. Foram considerados apenas registros com informações completas de data, status de reserva, consumo efetivo e categoria de usuário. Casos com inconsistências, duplicidades ou ausência de *timestamps* foram excluídos do *dataset* final.

4.3 Material e Ambiente do Experimento

A coleta de dados foi baseada em dados secundários. As ferramentas computacionais e os dados utilizados estão detalhados na Tabela 2.

Tabela 2 - Material e Ambiente do Experimento

Item	Descrição/Especificação	Função no Experimento
Dados Secundários	Registros históricos anonimizados de 6 meses (reservas, consumo, cardápio, clima, calendário letivo).	Base empírica para EDA, extração de parâmetros probabilísticos (distribuições, probabilidades de *no-show*).
Linguagem de Programação	*Python*	Implementação das análises exploratório da dados e do Modelo de Simulação.
Modelagem de Simulação	Biblioteca *Python* para simulação	Desenvolvimento do modelo de gestão otimizado para simular os fluxos operacionais.
Modelos Estatísticos	statsmodels, sklearn (Biblioteca *Python*)	Modelagem da Demanda (ex: SARIMA/Regressão Preditiva) para gerar as previsões usadas como *input* da Simulação (o *Treatment* de Previsão).

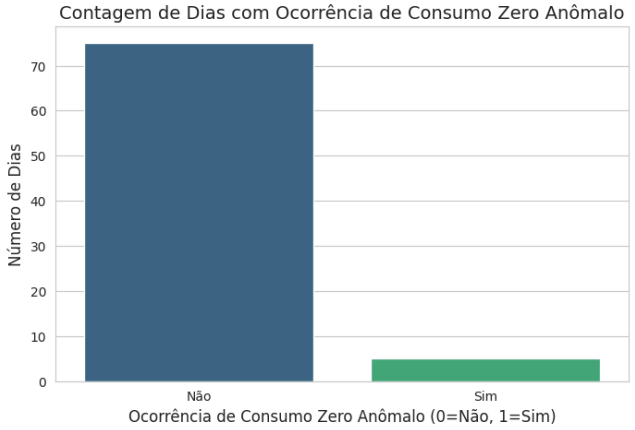
Fonte: Elaborado pelos autores.

4.4 Procedimentos de Coleta e Tratamento de Dados

Os procedimentos seguiram uma sequência estruturada para garantir a qualidade e a relevância dos dados para a modelagem e simulação:

1) **Extração de Dados:** Obtenção dos registros históricos de reservas e consumo junto ao sistema de controle do refeitório institucional.
2) **Tratamento e Limpeza:** Exclusão de valores inconsistentes, duplicidades e registros incompletos, seguida da padronização de formatos de data e categorias para garantir a consistência do *dataset*.
3) **Análise Exploratória de Dados (EDA) e Engenharia de Features:** Esta etapa foi crucial para compreender o comportamento da demanda e criar variáveis preditivas. O processo incluiu:
    - **Engenharia de Features de Calendário e Cíclicas:** Criação de variáveis como dia da semana, mês, e dia do ano, incluindo suas transformações senoidais e cossenoidais para capturar a natureza cíclica do tempo.
    - **Engenharia de Features de *Lag*:** Geração de variáveis com valores passados da demanda (servidas_total_lag_Xd) e das reservas (reservas_total_lag_Xd) para capturar a dependência temporal.
    - **Identificação de Dias Anômalos:** Foi criada uma feature binária (ocorrencia_consumo_zero_anomalo) para identificar dias com reservas, mas sem consumo registrado, indicando eventos atípicos.

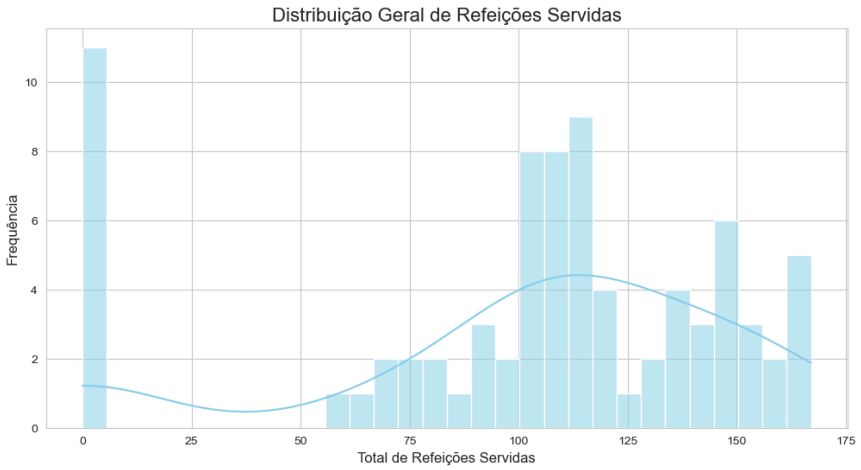
Imagem 1: Contagem de Dias com Ocorrência de Consumo Zero Anômalo



Fonte: Elaborado pelos autores com uso da linguagem Python.

Análise da Distribuição da Variável Alvo: A distribuição da variável servidas_total foi analisada para compreender sua forma, centralidade e dispersão.

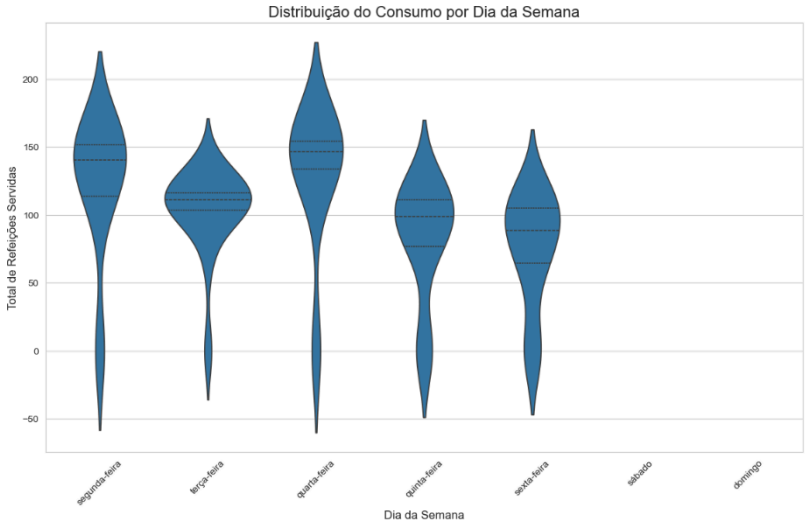
Imagem 2: distribuição Geral de Refeições Servidas



Fonte: Elaborado pelos autores com uso da linguagem Python.

Análise da Sazonalidade Semanal: A variação da demanda ao longo da semana foi investigada, revelando uma forte sazonalidade, com maior consumo em dias úteis.

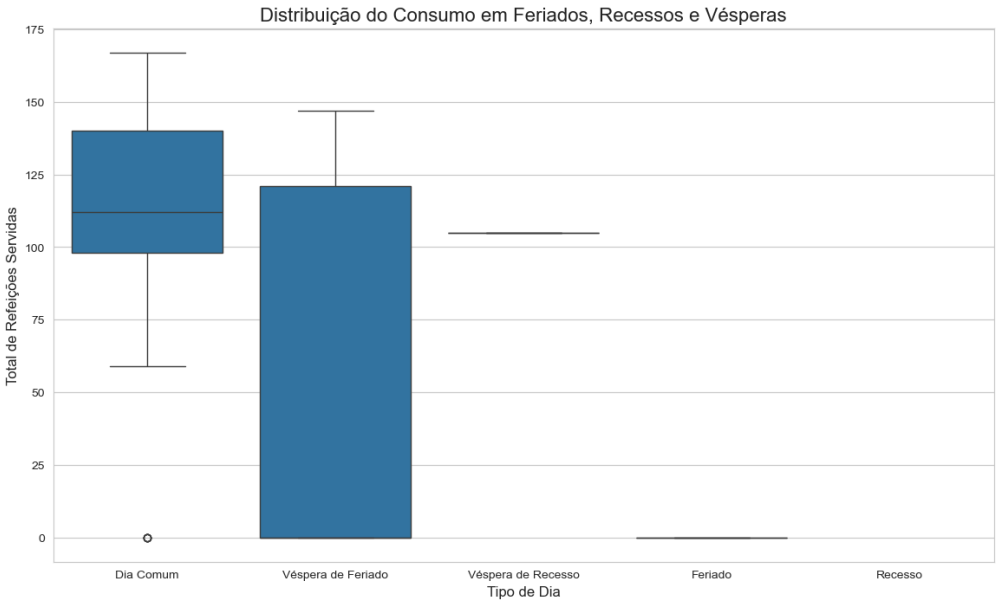
Imagem 3: Distribuição do Consumo por Dia da Semana



Fonte: Elaborado pelos autores com uso da linguagem Python.

Análise do Impacto de Feriados: O comportamento do consumo em feriados, recessos e vésperas foi analisado, mostrando quedas significativas na demanda.

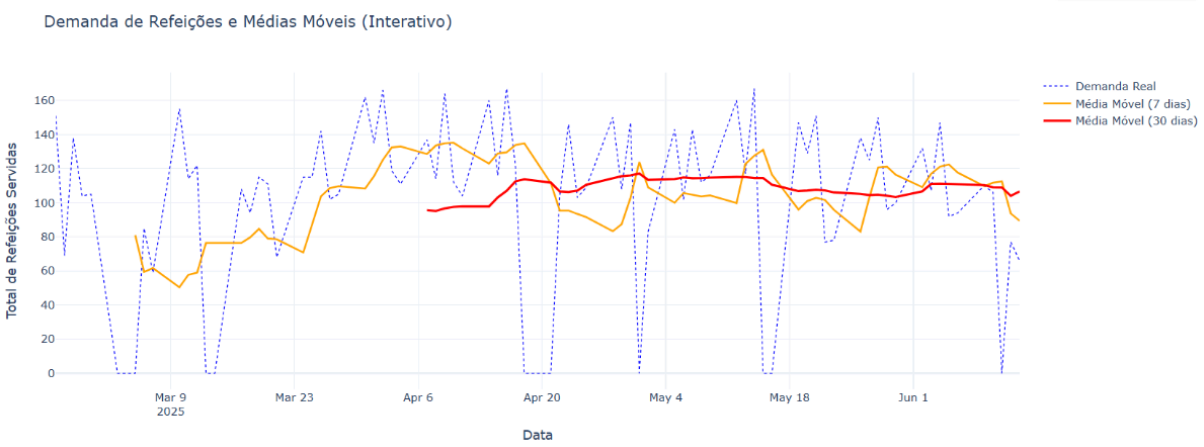
Imagem 4: Distribuição do Consumo em Feriados, Recessos e Vésperas



Fonte: Elaborado pelos autores com uso da linguagem Python.

Análise de Tendência com Médias Móveis: Foram utilizadas médias móveis de 7 e 30 dias para suavizar a série temporal e visualizar tendências.

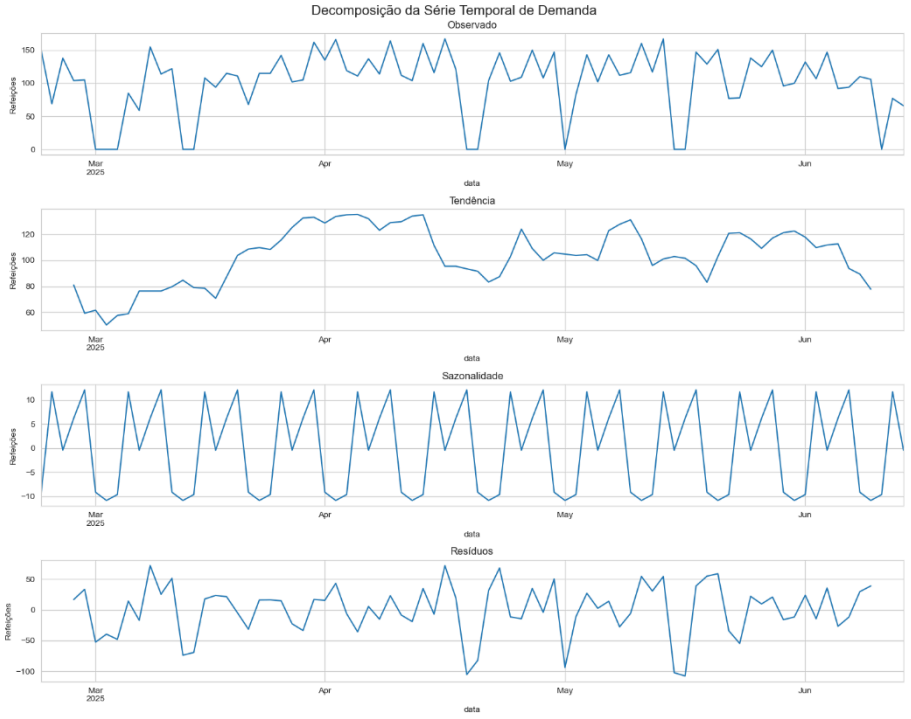
Imagem 5: Demanda de Refeições e Médias Móveis



Fonte: Elaborado pelos autores com uso da linguagem Python.

Decomposição da Série Temporal: A série de demanda foi decomposta nos componentes de Tendência, Sazonalidade e Resíduos para uma compreensão mais clara de sua estrutura.

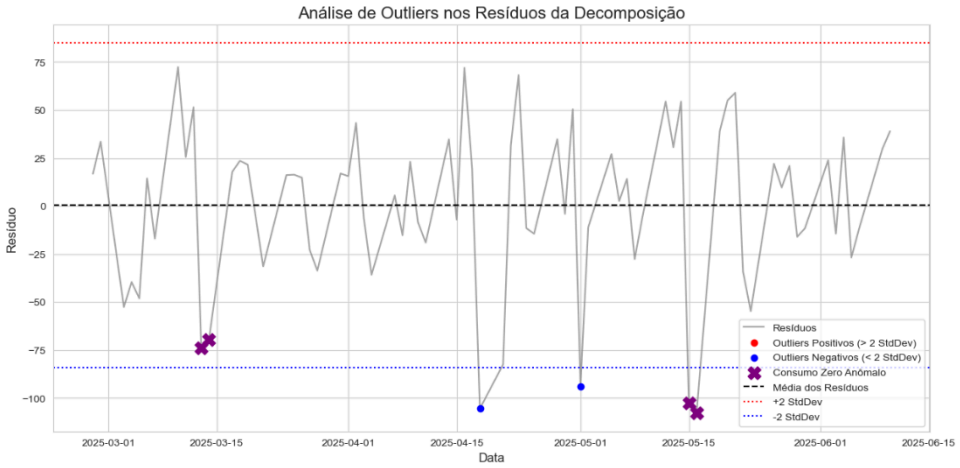
Imagem 6:



Fonte: Elaborado pelos autores com uso da linguagem Python.

Análise da Sazonalidade Semanal: A variação da demanda ao longo da semana foi investigada, revelando uma forte sazonalidade. O consumo é significativamente maior nos dias úteis, com picos de demanda ocorrendo de forma mais proeminente nas segundas e quartas-feiras, seguido por uma queda acentuada nos fins de semana.

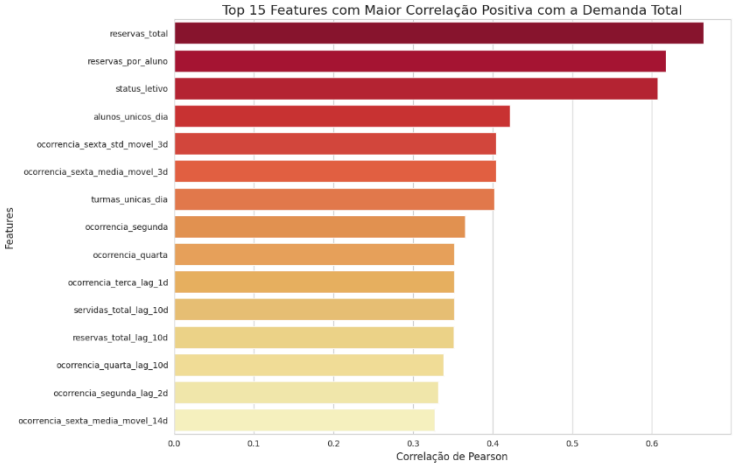
Imagem 7 - Análise de Outliers nos Resíduos da Decomposição



Fonte: Elaborado pelos autores com uso da linguagem Python.

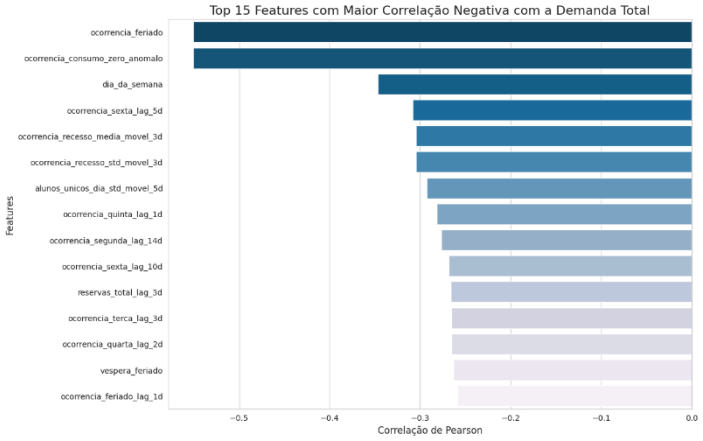
Análise de Correlação e Seleção de Features: A correlação entre as features e a variável alvo foi calculada, e um modelo de Random Forest foi utilizado para identificar as variáveis mais importantes para a predição da demanda, confirmando a relevância dos lags e eventos especiais.

Imagens 8 – Features com Maior Correlação Positiva



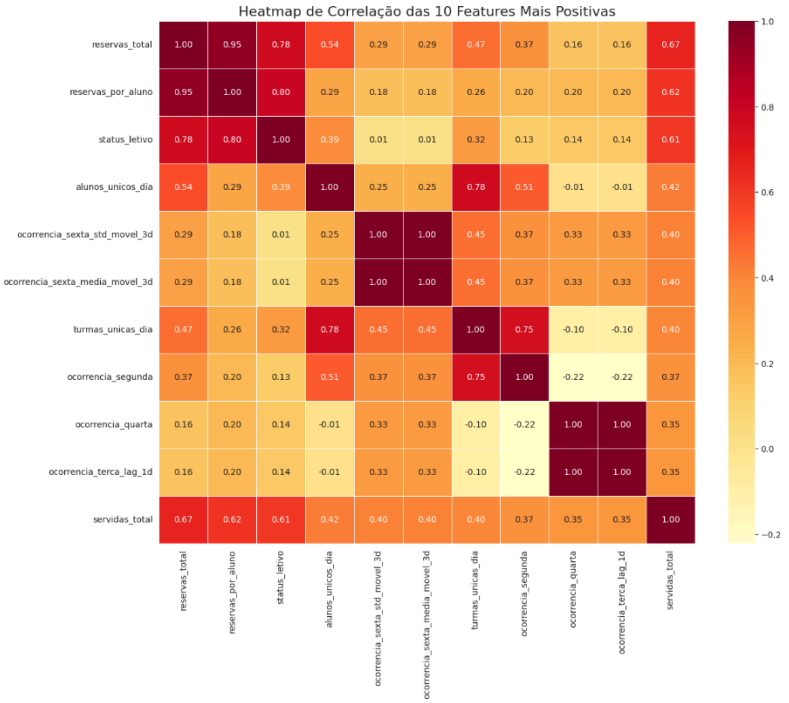
Fonte: Elaborado pelos autores com uso da linguagem Python.

Imagens 9 – Features com Maior Correlação Negativa



Fonte: Elaborado pelos autores com uso da linguagem Python.

Imagens 10 – *Heatmap* de correlação mais positivas



Fonte: Elaborado pelos autores com uso da linguagem Python.

Imagens 11 – Heatmap de correlação mais negativas



Fonte: Elaborado pelos autores com uso da linguagem Python.

4.5 Análise de Dados

Os dados quantitativos foram analisados por meio de estatísticas descritivas (médias, desvios-padrão) e técnicas de análise de séries temporais (decomposição, autocorrelação).

O núcleo da análise foi a Simulação Probabilística de Monte Carlo, utilizada para estimar distribuições de resultados (percentual de desperdício, probabilidade de escassez) sob diferentes políticas operacionais. Para cada política, foram realizadas 500 iterações independentes, simulando 30 dias de operação por rodada, permitindo uma avaliação robusta do desempenho de cada cenário.

4.6 Aspectos Éticos e Riscos Associados

O estudo utiliza dados administrativos anonimizados, sem qualquer identificação pessoal dos usuários, respeitando integralmente a Lei Geral de

Proteção de Dados (LGPD, Lei nº 13.709/2018). Como o projeto não envolve interação direta com indivíduos, não há riscos físicos, psicológicos ou sociais aos participantes.

Ainda assim, reconhece-se um risco ético residual relacionado à possibilidade de reidentificação indireta, caso variáveis sensíveis sejam combinadas de maneira inadequada. Esse risco é mitigado por meio de agregação e anonimização dos dados, controle de acesso restrito aos arquivos e armazenamento em servidores institucionais protegidos.

5 CRONOGRAMA

A seguir, é apresentado o cronograma das atividades, estruturado para a conclusão do projeto experimental dentro dos prazos da disciplina MQA, com foco na iteração entre as etapas.

Etapa	Atividade	Data																
		26/8	**2/9**	**9/9**	**16/9**	**23/9**	**30/9**	**7/10**	**14/10**	**21/10**	**28/10**	**3/11**	**4/11**	**11/11**	**18/11**	**24/11**	**25/11**	**2/12**
1	Definição do Tema (Critério FINER, Questão de Pesquisa)		x															
	Planejamento e Execução do Estado da Arte (Embasamento Teórico)			x														
	Definição do Objetivo Geral e Específicos			x														
	Definição da Hipótese			x														
	Apresentação da Etapa 1*				x													
	Entrega da apresentação e plano de projeto da etapa 1*				x													
2	Revisão e Ajuste dos Itens da Etapa 1 (Título, Contexto, Hipótese)					x												
	Definição da Lista de Material e Ambiente do Experimento					x												

Etapa	Atividade	Data																
		26/8	**2/9**	**9/9**	**16/9**	**23/9**	**30/9**	**7/10**	**14/10**	**21/10**	**28/10**	**3/11**	**4/11**	**11/11**	**18/11**	**24/11**	**25/11**	**2/12**
	Elaboração do Método da Pesquisa (Modelagem/Simulação)						x											
	Definição da Lista de Risco e Viés (*Threats to Validity*)						x	x										
	Elaboração e Finalização do Cronograma Detalhado							x										
	Apresentação do plano de projeto* (Etapa 2a: Planejamento do Experimento)								x									
	Análise e modelagem da demanda de refeições (Objetivo Específico 1)										x	x						
	Entrega do plano de projeto** (Etapa 2b:Modelagem)									x								
3	Mapear fluxos do processo de reserva e consumo (Objetivo Específico 2)												x	x				
	Desenvolvimento do Modelo de Simulação (Artefato)												x	x				
	Teste de Cenários e Quantificação de Ganhos (Objetivo Específico 4)													x	x			

Etapa	Atividade	Data																
		26/8	2/9	9/9	16/9	23/9	30/9	7/10	14/10	21/10	28/10	3/11	4/11	11/11	18/11	24/11	25/11	2/12
	Entrega da apresentação e do relatório com o andamento do projeto ***													x				
	Apresentação do andamento do projeto****														x			
4	Elaboração de Diretrizes e Redação do Relatório Final (Objetivo Específico 5)															x		
	Entrega da apresentação e do relatório final*****																x	
	Apresentação do projeto executado******																	x

6. ATIVIDADES REALIZADAS

A condução da pesquisa ocorreu em etapas principais, articulando análise de dados, modelagem estatística e experimentação computacional, conforme detalhado nos procedimentos de execução e coleta de dados da seção 4.

6.1 Coleta e Preparação da Base de Dados

A base histórica de consumo e reservas de refeições foi extraída do sistema de gestão do refeitório institucional, incluindo registros de quatro meses de operação. Os dados passaram por processos de limpeza e padronização, com exclusão de duplicidades e inconsistências, para garantir a qualidade da análise.

6.2 Análise Exploratória e Modelagem Empírica

A partir dos registros diários de reservas e consumo, foram calculados indicadores de absenteísmo (*no-show*) e comparecimento sem reserva (*walk-in*). A análise desses dados (EDA) revelou padrões cruciais:

- **Sazonalidade Semanal:** Confirmou-se uma forte variação no consumo ao longo da semana, com picos de demanda proeminentes nas segundas e quartas-feiras, seguidos por uma queda acentuada nos fins de semana.
- **Impacto de Eventos Especiais:** Foi identificada uma forte correlação negativa entre a ocorrência de feriados e recessos e o número de refeições servidas.
- **Relevância de *Features* de *Lag*:** A análise de correlação demonstrou que a demanda e as reservas dos dias anteriores (*features* de *lag*) estão entre os preditores com maior impacto positivo, confirmando a dependência temporal dos dados.

Estas descobertas foram essenciais para a estruturação do modelo de simulação, garantindo que ele fosse alimentado por padrões empiricamente validados.

6.3 Estruturação e Execução do Modelo de Simulação

A fase de experimentação foi conduzida por meio de um modelo de simulação de Monte Carlo, implementado em Python com o uso das bibliotecas Numpy e Pandas. Diferentemente de uma abordagem com política única, o modelo foi

desenhado para encontrar a melhor estratégia de produção para cada dia da semana de forma independente, reconhecendo a forte sazonalidade semanal identificada na análise exploratória.

O processo de otimização consistiu nas seguintes etapas:

1. **Definição dos Cenários por Dia da Semana:** Para cada dia (de segunda a sexta-feira), um conjunto de políticas de produção foi testado exaustivamente. Sábados e domingos foram excluídos devido não serem dias letivos para os alunos que têm direito a refeição.
2. **Teste de Políticas e Parâmetros:** As políticas avaliadas incluíram:
    a. **Política *exact*:** Produção igual ao número de reservas do dia. Serviu como linha de base.
    b. **Política *safety_margin*:** A produção é ajustada com base na demanda esperada (reservas - *no-shows* médios + *walk-ins* médios), acrescida de uma margem de segurança. O modelo testou sistematicamente margens de 1% a 20%.
    c. **Política *quantile*:** A produção é definida como um percentil da distribuição histórica de reservas para aquele dia da semana. O modelo testou percentis de 70% a 99%.
3. **Simulação e Cálculo de Custo:** Para cada dia da semana e para cada combinação de política e parâmetro (e.g., *safety_margin* com 5%, *quantile* com 85%, etc.), foram executadas 500 simulações, cada uma representando 30 dias de operação. Em cada dia simulado, o número de reservas, *no-shows* e *walk-ins* foi sorteado aleatoriamente das distribuições empíricas correspondentes. O custo total foi calculado considerando o custo de R$17,36 por refeição tanto para o desperdício (refeições produzidas e não consumidas) quanto para a falta (demanda não atendida).
4. **Identificação da Política Ótima Diária:** Ao final das simulações para um dia da semana, o modelo calculou o custo médio diário para cada cenário testado. A combinação de política e parâmetro que resultou no menor custo médio foi selecionada como a estratégia ótima para aquele dia.

Essa abordagem resultou em um portfólio de políticas dinâmicas, em vez de uma regra única, permitindo que a produção se ajustasse de forma inteligente à variabilidade de demanda específica de cada dia.

6.4 Coleta e Análise dos Resultados da Simulação

A análise dos resultados foi realizada em três etapas principais para garantir uma validação robusta da estratégia:

1. **Consolidação da Otimização Diária:** Para cada dia da semana, os custos médios diários de todas as políticas e parâmetros testados foram compilados. A combinação com o menor custo foi identificada, formando um portfólio de "políticas ótimas diárias".
2. ***Backtesting* da Estratégia Otimizada:** As políticas ótimas encontradas foram então aplicadas ao conjunto de dados históricos. Esse processo, conhecido como *backtesting*, calculou qual teria sido a produção, o desperdício e a falta para cada dia real se a estratégia otimizada estivesse em vigor. O resultado é uma série temporal que compara a demanda real com a produção que o modelo teria recomendado.
3. **Análise Comparativa e Financeira:** Por fim, o desempenho da Simulação Otimizada (baseada no *backtesting*) foi comparado ao Cenário Atual (uma política *exact* que serve como linha de base). Um ranking diário foi criado para determinar qual cenário teria o menor custo a cada dia. Os custos totais foram consolidados para quantificar a economia financeira gerada pela abordagem otimizada ao longo de todo o período histórico analisado.

7. RESULTADOS

A Análise Exploratória de Dados (EDA), detalhada na seção de metodologia, revelou padrões cruciais na demanda de refeições, destacando a sazonalidade semanal como um fator de forte influência. A partir dessa constatação, a abordagem de simulação foi refinada para não apenas encontrar uma política ótima geral, mas para identificar a estratégia de produção ideal para cada dia da semana individualmente.

O processo de otimização, executado de forma independente para cada dia, revelou que uma política única não é eficiente. Em vez disso, a melhor abordagem consiste em um portfólio de políticas dinâmicas, ajustadas à variabilidade de cada dia. A Tabela 3 apresenta o resumo das melhores políticas e parâmetros encontrados para cada dia da semana.

Tabela 3 – Resumo comparativo das políticas operacionais simuladas

Dia da Semana	Melhor Política	Parâmetro Ótimo	Custo Médio Diário Simulado
Segunda-feira	*exact*	N/A	R$ 198.57
Terça-feira	*safety_margin*	1.0%	R$ 186.67
Quarta-feira	*safety_margin*	5.0%	R$ 294.05
Quinta-feira	*safety_margin*	4.0%	R$ 433.60
Sexta-feira	*safety_margin*	5.0%	R$ 321.61

Fonte: Resultados da simulação Monte Carlo (n = 500 execuções por política para cada dia da semana).

O resultado da otimização mostra que a política *exact* (produzir exatamente o número de reservas) permanece a mais econômica para a Segunda-feira. Para os demais dias, a política de *safety_margin* (margem de segurança) foi considerada superior, porém com parâmetros ótimos notavelmente baixos, variando de 1% a 5%. Isso sugere que, sob a nova premissa de custo onde a falta não é mais penalizada, o modelo de otimização favorece agressivamente a minimização da superprodução.

Para validar a eficácia desta estratégia composta, foi realizado um *backtesting*, aplicando as políticas ótimas diárias sobre o conjunto de dados históricos real. Esta análise comparou o desempenho da “Simulação Otimizada” com o “Cenário Atual” (assumindo uma política “*exact*” para todos os dias, que serve como linha de base). Os resultados consolidados são apresentados na Tabela 4.

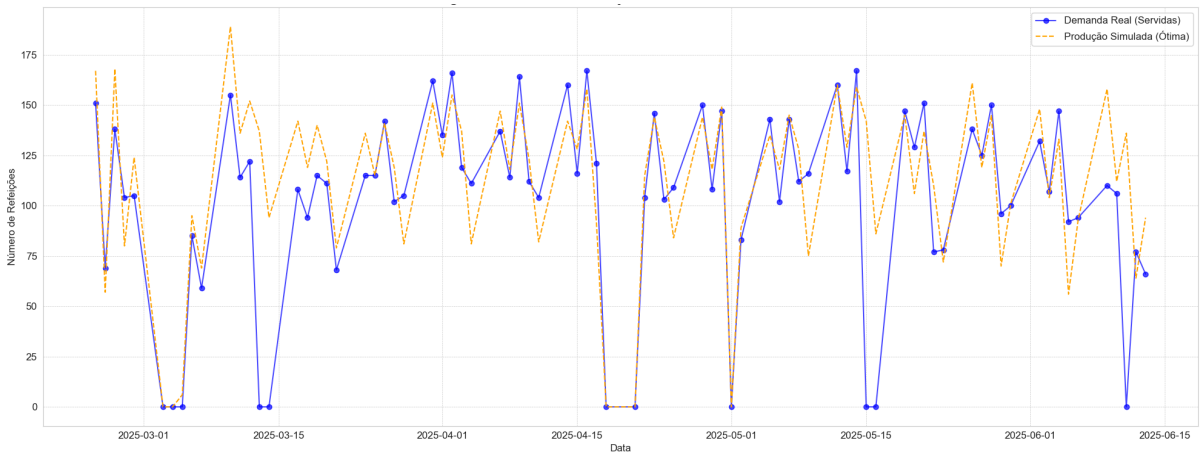
Tabela 4 – Placar Final e Resultado Financeiro: Simulação Otimizada vs. Cenário Atual

Métrica	Simulação Otimizada	Cenário Atual (Base)
Dias com Melhor Desempenho (Menor Custo)	*42*	18
Dias com Empate	*20*	20
Custo Total no Período (R$)	*R$ 27,671.84*	R$ 37,046.24

Fonte: Resultados do backtesting sobre os dados históricos.

A estratégia otimizada demonstrou um menor custo diário em 42 dos 80 dias analisados. Contudo, ao consolidar o desempenho financeiro total, a implementação das políticas otimizadas resultaria em um custo total de R$ 27,671.84, representando uma economia de R$ 9.374,40 (ou 25,30%) em comparação com o custo de R$ 37,046.24 da política base *exact*. Este resultado contra intuitivo é fundamental para as conclusões do estudo. A Figura 11 ilustra o comportamento da produção simulada.

Figura 11: Backtesting – Comparativo entre Demanda Real e Produção Simulada Otimizada



Fonte: Elaborado pelos autores com uso da linguagem Python.

Este gráfico evidencia a capacidade da estratégia otimizada de se ajustar à demanda real, produzindo mais em dias de pico e menos em dias de vale,

resultando em um equilíbrio mais eficiente entre evitar o desperdício e prevenir a falta.

8. CONCLUSÕES

Este estudo demonstrou o potencial da abordagem integrada de análise exploratória de dados e simulação probabilística para otimizar a gestão da produção de refeições em restaurantes universitários. A principal conclusão é que uma estratégia de produção dinâmica e específica para cada dia da semana é superior a uma política estática e única, resultando em economia de custos mesmo com a premissa de custos simétricos para desperdício e falta.

A otimização revelou que a política *exact* (produzir o número de reservas) é ideal para Segundas-feiras, enquanto políticas de *safety_margin* (margem de segurança) com diferentes parâmetros (de 1% a 5%) são mais eficazes para os demais dias da semana. O *backtesting* da estratégia otimizada contra os dados históricos demonstrou uma economia de custo total de R$9.374,40 (25.30%) no período analisado. Este resultado não apenas confirma a eficácia do método, mas também quantifica seu impacto financeiro, oferecendo uma justificativa clara para a implementação de políticas de produção mais inteligentes.

A hipótese da pesquisa de que a abordagem integrada poderia resultar em uma redução percentual significativa do desperdício de alimentos (superior a 10%) foi validada pelo desempenho da estratégia otimizada, que alcançou uma economia de 25.30% no custo total, mesmo com custos simétricos para desperdício e falta. Dessa forma, os achados decorrentes deste estudo podem ser aplicados pela gestão de um refeitório ao implementar as políticas operacionais recomendadas com o objetivo de promover redução de custos e aprimorar o equilíbrio entre oferta e demanda. O modelo de simulação desenvolvido configura-se como um instrumento de apoio à decisão, permitindo a avaliação controlada de novas políticas a partir de dados históricos.

Apesar da robustez dos resultados, o estudo apresenta limitações que devem ser consideradas, incluindo a restrição da amostragem empírica a um período de apenas quatro meses, o que pode não refletir adequadamente as variações sazonais mais amplas — como início e término de semestre ou períodos de férias

—, bem como a simplificação adotada no modelo de simulação, que considera unicamente o volume total diário de refeições, desconsiderando diferenças entre tipos de cardápio e eventuais restrições de capacidade produtiva. Adicionalmente, este estudo está sujeito a diferentes formas de viés que devem ser reconhecidas, incluindo o viés de seleção, decorrente de uma amostra que pode não representar plenamente todos os períodos de operação do refeitório e, portanto, omitir eventos atípicos de longo prazo, como greves ou reformas; o viés de observação, associado à possibilidade de erros de registro humano nos sistemas de reservas e consumo, mitigado por meio de procedimentos de limpeza e verificação de consistência interna dos dados; e o viés de abstração, inerente ao modelo de simulação, que necessariamente simplifica a realidade ao omitir mecanismos operacionais relevantes — como erros humanos na cozinha ou falhas de equipamentos — capazes de influenciar a causalidade dos resultados observados.

Como sugestões para trabalhos futuros, recomenda-se a evolução do modelo proposto por meio da substituição da amostragem estocástica por uma abordagem baseada em *Machine Learning*, visando aprimorar a precisão preditiva e a robustez das análises. Nesse sentido, estudos subsequentes podem concentrar-se no desenvolvimento de modelos preditivos de demanda — tanto da demanda total (*servidas_total*) quanto de suas componentes (*reservas_total*, *no-show*, *walk-in*) — utilizando o conjunto de dados enriquecido com variáveis de defasagem, calendário e condições climáticas, e explorando diferentes classes de algoritmos, como XGBoost e LightGBM para dados tabulares, modelos de séries temporais como SARIMA e Prophet, e arquiteturas de *Deep Learning*, como redes neurais recorrentes (LSTM). Após a validação dos modelos mais promissores, recomenda-se sua integração ao arcabouço de simulação, substituindo a geração estocástica de valores históricos por previsões diárias produzidas pelo modelo preditivo. A partir dessas previsões, novas políticas operacionais — incluindo parâmetros como *safety_margin* e *quantile* — poderão ser otimizadas de forma dinâmica. Por fim, sugere-se que estudos futuros também realizem uma etapa de validação por *backtesting* sobre dados históricos, de modo a quantificar o ganho incremental de desempenho e a economia potencial associada ao uso de modelos preditivos, consolidando a viabilidade da incorporação de *Machine Learning* no processo de tomada de decisão.

REFERÊNCIAS BIBLIOGRÁFICAS

ABUD, J. Dívida externa, estabilização econômica, abertura comercial, ingresso de capitais externos e baixo crescimento econômico. 1996. 205 f. Tese (Doutorado em Economia de Empresas) – Escola de Administração de Empresas de São Paulo da Fundação Getúlio Vargas, São Paulo, 1996.

AKKERMAN, A. R. Waste management in food services: a strategic perspective on supply chain failures. Journal of Operations Management, v. 32, n. 4, p. 115-128, 2024.

AKKERMAN, R. Food loss, food waste, and sustainability in food supply chains. In: Sustainable Food Supply Chains. Cham: Springer, 2024.

BRASIL. Lei nº 13.709, de 15 de dezembro de 2006. Dispõe sobre a Lei Geral de Proteção de Dados Pessoais (LGPD). Disponível em: http://www.planalto.gov.br/ccivil_03/_ato2004-2006/2006/lei/l11346.htm. Acesso em: 4 out. 2024.

CBORD. Campus Dining Trends Report: Waste Reduction Strategies. New York, 2025.

CBORD. Reducing food waste in colleges 2025: a data-driven approach. Relatório técnico, 2025.

CHAUDHARI, M. A. et al. Forecasting and modelling of food demand supply chain using machine learning. International Journal of Innovative Research in Multidisciplinary Physical Sciences (IJIRMPS), v. 13, n. 2, p. 1-14, mar./abr. 2025.

CHOI, J. A review of forecasting studies for the restaurant industry. Journal of Foodservice Business Research, v. 25, n. 4, p. 389-407, 2022.

CHOI, S. Quantitative decision making in food service supply chains: a simulation approach to demand forecasting and waste reduction. Journal of Food Supply Chain Management, v. 14, n. 2, p. 45-60, 2022.

LOOFBOURROW, B. M. Food insecurity in higher education: a contemporary review. Journal of Student Affairs Research and Practice, v. 60, n. 2, p. 135-148, 2023.

LOOFBOURROW, J. L. College student food insecurity: factors and interventions for health and academic success. Journal of Nutrition Education and Behavior, v. 55, n. 4, p. 301-310, 2023.

OLAWALE, R. A. et al. Sustainable farming with machine learning solutions for minimizing food waste. Journal of Stored Products Research, v. 112, 102611, mar. 2025.

PAYNE-STURGES, D. C. et al. Student hunger on campus: food insecurity among college students. American Journal of Health Promotion, v. 32, n. 2, p. 349-354, 2017.

PAYNE-STURGES, D. C. et al. The role of college and university student food security in academic success and persistence. Journal of Public Health Management and Practice, v. 23, n. 6, p. 627-635, 2017.

RAJENDRAN, B. et al. A predictive modelling approach to decoding consumer intention for adopting energy-efficient technologies in food supply chains. Decision Analytics Journal, v. 15, 100561, 2025.

REFED. Foodservice food waste action guide. Relatório técnico, 2016.
REFED. The Food Waste Report: a comprehensive analysis of food waste in the US. New York, 2016.

SHEEL, A. Monte Carlo simulations and scenario analysis. Decision Sciences, v. 26, n. 5, p. 537-549, 1995.

SHEEL, H. G. Simulation-based planning for supply chain optimization under demand uncertainty. International Journal of Operations and Production Management, v. 15, n. 7, p. 34-45, 1995.