XX Simpósio dos Programas Profissionais de Pós-Graduação
Coordenadoria Geral de Pós-Graduação, Extensão e Pesquisa
São Paulo/SP – 04, 05 e 06 de novembro de 2025

Programas Profissionais de Pós-Graduação:
perspectivas e políticas em face das necessidades locais e globais

Relato Técnico

Análise Exploratória de Dados para Previsão da Demanda de Refeições e Redução do Desperdício Alimentar em Instituição de Ensino

Michel Silva de Souza
0009-0003-3951-202X

Dr. Carlos Hideo Arima
0000-0001-7922-0943

Dr. Rafael Nobre Orsi
0000-0003-4719-0131

Patrícia Aparecida de Souza
0009-0004-9445-6080

Resumo
O desperdício de alimentos é um problema global que compromete a segurança alimentar e a sustentabilidade, sendo particularmente crítico em instituições de ensino. Este relato técnico detalha a Análise Exploratória de Dados (EDA) que fundamenta o desenvolvimento de um sistema de previsão de demanda de refeições com Machine Learning, visando otimizar recursos e reduzir o desperdício. O estudo focou em dados históricos de consumo, reservas, cardápios e fatores contextuais, como o clima, em uma instituição de ensino. Conforme a metodologia CRISP-ML(Q), a EDA foi uma etapa crucial, envolvendo pré-processamento de dados brutos, agregação para granularidade diária e a integração de features de cardápio vetorizadas com Word2Vec. A análise de padrões temporais revelou tendências sazonais e semanais distintas, com picos de demanda nos dias úteis e uma forte correlação entre o número de reservas e as refeições efetivamente servidas, validando as reservas como um preditor primário. A distribuição da demanda mostrou-se bimodal, distinguindo claramente dias letivos de não letivos. Para aprofundar a análise, a série temporal foi submetida a uma decomposição sazonal, comparando-se os modelos aditivo e multiplicativo. O modelo multiplicativo apresentou um ajuste superior (MAPE de 12,49%), confirmando que a sazonalidade é proporcional à tendência da demanda. Os resultados indicaram a complexidade da série e a necessidade de modelos mais avançados, como *Random Forest* e *XGBoost*, que possam capturar relações não lineares. Este estudo reforça que uma EDA robusta é essencial para subsidiar o desenvolvimento de modelos preditivos eficazes, promovendo a sustentabilidade na gestão de recursos alimentares em ambientes educacionais.

Palavras-chave: Desperdício de alimentos. Previsão de demanda. Machine learning. Análise Exploratória de Dados. Sustentabilidade.

Abstract
Food waste is a global issue that compromises food security and sustainability, being particularly critical in educational institutions. This technical report details the Exploratory Data Analysis (EDA) that underpins the development of a meal demand forecasting system using Machine Learning, aimed at optimizing resources and reducing food waste. The study focused on historical data of consumption, reservations, menus, and contextual factors, such as weather, within an educational institution. Following the CRISP-ML(Q) methodology, the EDA was a crucial step, involving the preprocessing of raw data, aggregation to daily granularity, and the integration of menu features vectorized with Word2Vec. The analysis of temporal patterns revealed distinct seasonal and weekly trends, with demand peaking on weekdays and a strong

correlation between reservations and meals actually served, validating reservations as a primary predictor. The demand distribution was found to be bimodal, clearly distinguishing between school days and non-school days. To deepen the analysis, the time series was subjected to seasonal decomposition, comparing additive and multiplicative models. The multiplicative model showed a superior fit (MAPE of 12.49%), confirming that seasonality is proportional to the demand trend. The results indicated the complexity of the series and the need for more advanced models, such as Random Forest and XGBoost, which can capture non-linear relationships. This study reinforces that a robust EDA is essential to support the development of effective predictive models, promoting sustainability in food resource management within educational environments.

Keywords: Food waste. Demand forecasting. Machine learning. Exploratory Data Analysis. Sustainability.

1 Introdução

O desperdício de alimentos é um problema global, com impactos substanciais na segurança alimentar, na sustentabilidade ambiental e na economia mundial (FAO, 2021; Gunders, 2012). No Brasil, essa questão é ainda mais crítica, dada a persistência da desigualdade social e a insegurança alimentar, o que torna a gestão eficiente dos recursos alimentares uma prioridade inadiável. A relação entre vulnerabilidade social e a segurança alimentar no país tem sido amplamente documentada (BEZERRA et al., 2024), justificando a urgência em otimizar o uso de recursos. Em ambientes institucionais, como escolas e universidades, as operações de serviço de alimentação em larga escala são particularmente vulneráveis ao desperdício, gerando perdas financeiras e ambientais significativas.

Escolas são identificadas como um setor prioritário para a redução do desperdício de alimentos devido à dimensão de suas operações de serviço de alimentação, especialmente aquelas que recebem financiamento através de programas como o *National School Lunch Program* nos Estados Unidos (ELNAKIB et al., 2021). O desafio é complexo, pois o desperdício ocorre em várias etapas da cadeia de suprimentos, mas uma parcela considerável é gerada na fase de consumo, seja em refeições fora de casa ou no ambiente doméstico. No contexto educacional, isso se traduz no "*plate waste*" (desperdício no prato), que pode variar amplamente, de 12% a 73,3% dos componentes alimentares selecionados, com destaque para vegetais, grãos e frutas (ELNAKIB et al., 2021).

A importância de abordar o desperdício de alimentos em instituições de ensino abrange aspectos econômicos, ambientais, a formação de hábitos alimentares saudáveis e a promoção da educação para a sustentabilidade. A precisão na previsão da demanda de refeições contribui para mitigar esse problema, permitindo um planejamento da produção e do serviço, e reduzindo o excesso de alimentos preparados e a falta de refeições.

Nesse cenário, a aplicação de técnicas de *Machine Learning* (ML) emerge como uma estratégia promissora para otimizar a gestão alimentar e reduzir o desperdício, conforme demonstrado em diversos estudos de previsão de demanda em serviços de catering (RODRIGUES et al., 2024; TURKER, 2025). Tais métodos, por serem orientados a dados (*data-driven*), são úteis em extrair relações complexas, identificar padrões e tendências, e quantificar o impacto de intervenções no sistema. Essa capacidade analítica é imprescindível para a formulação de soluções mais precisas e eficientes, que apoiem o desenvolvimento de sistemas de gestão (HU et al., 2024).

Este relato técnico, que se baseia e expande um trabalho anterior (SOUZA; ORSI, 2024), tem como objetivo principal detalhar a Análise Exploratória de Dados (EDA) realizada sobre os dados de demanda de refeições em uma instituição de ensino. A EDA é uma etapa crítica no ciclo de vida de desenvolvimento de modelos de ML, conforme

preconizado por metodologias como CRISP-ML(Q) (IPKOVICH et al., 2024), e é primordial para o “entendimento dos dados” e “preparação dos dados” (IPKOVICH et al., 2024). Por meio da EDA, o estudo visa não apenas obter a estrutura e as características do *dataset*, mas também identificar variáveis influenciadoras e padrões temporais que subsidiarão o desenvolvimento e o aprimoramento de modelos preditivos para a demanda de refeições, contribuindo, assim, de forma eficaz para a redução do desperdício alimentar e a promoção da sustentabilidade na instituição.

2 Objetivo

Este relato técnico tem como objetivo principal detalhar a Análise Exploratória de Dados (EDA) e as etapas de pré-processamento realizadas sobre os dados de consumo e reservas de refeições em uma instituição de ensino. Busca-se, através da EDA, identificar padrões, tendências e a influência de diversas variáveis contextuais e de cardápio na demanda diária de refeições servidas. Os objetivos específicos incluem:

- Descrever o processo de coleta, validação e tratamento dos dados brutos, enfatizando a importância da integridade e consistência para a construção de modelos preditivos robustos.
- Apresentar a metodologia de agregação de dados para a granularidade diária, integrando informações transacionais com *features* de cardápio e dados externos (climáticos), conforme a sua relevância para a previsão da demanda.
- Analisar os padrões temporais da série de demandas de refeições servidas, investigando sazonalidades semanais e tendências, e a distribuição das variáveis críticas.
- Identificar as correlações entre a demanda de refeições e variáveis explicativas como dia da semana, tipo de ocorrência, atributos do cardápio e condições meteorológicas.
- Subsidiar o desenvolvimento futuro de modelos preditivos de *Machine Learning* mais precisos para a demanda de refeições, contribuindo para a redução do desperdício alimentar e a otimização da gestão de recursos na instituição de ensino, alinhando-se aos princípios de sustentabilidade e eficiência operacional.

3 Análise do problema e solução proposta

O desperdício alimentar em instituições de ensino transcende a mera perda de recursos, configurando-se como um problema com implicações socioeconômicas e ambientais significativas. Conforme apontado por pesquisas, grandes volumes de desperdício são gerados especificamente na fase de consumo, em serviços de alimentação coletiva (KODORS et al., 2022). No contexto de uma instituição de ensino brasileira, o problema é agravado pela desigualdade social e pela necessidade de garantir o direito à alimentação adequada para todos, conforme evidenciado em estudos anteriores (SOUZA; ORSI, 2024).

A ineficiência no gerenciamento da demanda de refeições gera consequências que incluem perdas financeiras decorrentes da aquisição e preparo excessivo de alimentos, impactos ambientais relacionados ao descarte de resíduos orgânicos e comprometimento das metas institucionais de sustentabilidade (TURKER, 2025). A imprecisão na previsão da demanda pode ocasionar tanto o excesso de estoque, resultando em desperdício e elevação de custos, quanto a escassez de insumos, afetando a disponibilidade e o atendimento aos usuários (CHAUDHARI et al., 2025). Diante desse cenário, o uso de métodos de previsão de demanda constitui elemento central do planejamento estratégico.

Este estudo, em continuidade a investigações anteriores, tem como objetivo aprimorar a capacidade de previsão da demanda de refeições por meio de uma abordagem de EDA, que servirá de base para o desenvolvimento de modelos de ML. A EDA é considerada uma etapa primordial em projetos de ciência de dados, permitindo a compreensão das características do conjunto de dados, a identificação de relações entre variáveis, a detecção de outliers e anomalias, e a preparação dos dados para a modelagem preditiva (IPKOVICH et al., 2024).

A solução proposta se alinha à gestão do ciclo de vida de modelos de ML com garantia de qualidade (CRISP-ML(Q)), metodologia que prioriza as fases de "entendimento do negócio e dos dados" e "preparação dos dados" (IPKOVICH et al., 2024). Dada a complexidade da demanda de refeições, que é influenciada por múltiplos fatores, a abordagem orientada a dados (*data-driven*) torna viável a identificação de pontos de intervenção eficazes para o planejamento da sustentabilidade (IPKOVICH et al., 2024).

Para isso, é importante não apenas coletar dados de reservas e consumo, mas também integrar variáveis adicionais que comprovadamente influenciam a demanda, como o histórico de presença dos alunos, previsões climáticas, períodos de provas e o calendário escolar (SOUZA; ORSI, 2024). A literatura também reforça que fatores como o menu do dia, o número de clientes na semana anterior, as condições climáticas e o dia da semana são variáveis-chave na frequência de refeições (HU et al., 2024). Neste trabalho, as *features* de cardápio e os dados climáticos já foram integradas e analisadas como parte da construção de um *dataset* enriquecido. A inclusão desses elementos e uma EDA detalhada permite construir uma base de dados robusta, imprescindível para treinar modelos de ML capazes de capturar os padrões complexos e as tendências da demanda, gerando previsões mais precisas e promovendo, assim, uma redução efetiva do desperdício alimentar.

4 Implementação e resultados

A implementação da solução para a redução do desperdício alimentar em instituições de ensino requer uma abordagem sistemática que se inicia com a coleta, tratamento e análise de dados. Este processo, detalhado a seguir, é essencial para fornecer o embasamento necessário ao desenvolvimento de modelos preditivos eficazes.

4.1 Coleta e Validação de Dados

A fase inicial consistiu na coleta de dados detalhados sobre as refeições individuais servidas. Os dados brutos foram obtidos a partir de uma planilha eletrônica e incluíam informações detalhadas por aluno e por refeição, como data; código do aluno; tipo de refeição; reserva; servida; e consumo; além de variáveis contextuais como dia do ano; mês do ano; dia da semana; status letivo; tipo de ocorrência; e dados meteorológicos (temperatura média; temperatura máxima; temperatura mínima; soma de chuva; e velocidade máxima do vento).

A verificação e o tratamento dos dados foram etapas de alta importância, com a aplicação de checagens de estrutura e regras definidas para assegurar a consistência do *dataset*. Foi confirmada a presença de todas as colunas necessárias e a correta formatação da coluna de data. Adicionalmente, verificou-se que as colunas de data; consumo; refeições servidas; e reserva estavam completas e não continham valores negativos. Um procedimento de alerta foi implementado para identificar casos em que o número de refeições servidas superava o de reservadas, indicando potenciais

inconsistências que requerem análise (SOUZA; ORSI, 2024). A garantia da qualidade dos dados é condição indispensável para o treinamento eficaz de modelos de ML, pois a baixa qualidade dos dados é um obstáculo significativo ao processo preditivo (KANWAL et al., 2025).

Adicionalmente, um arquivo separado contendo variáveis de cardápio (*features*) foi carregado e validado. Este arquivo foi gerado a partir de informações de menu não estruturadas, que foram pré-processadas em vetores numéricos, utilizando técnicas de *Word2Vec* (HU et al., 2024). A junção dessas *features* de cardápio com o *DataFrame* principal foi realizada utilizando a coluna de data como chave. Foi verificada a unicidade das datas e eventuais valores nulos nas features foram preenchidos com zero, garantindo a prontidão de todas as informações para análises posteriores.

4.2 Agregação e Pré-processamento dos Dados Diários

Após a validação e junção, os dados por aluno e por refeição foram agregados para a granularidade diária. Esta etapa transformou cada registro individual em uma única observação diária com métricas sumarizadas. As regras de agregação incluíram a soma total de refeições servidas, reservas totais e consumo total, a contagem de alunos únicos por dia e turmas únicas por dia, e o primeiro valor de variáveis como status letivo; tipo de ocorrência; dia do ano; mês do ano; dia da semana; e as variáveis meteorológicas. As *features* de cardápio, representando os pratos servidos, foram mantidas com o primeiro valor do dia (*first*) e convertidas para o tipo inteiro.

Uma regra de negócio primordial aplicada nesta fase foi a correção das reservas e servidas para dias de feriado. Dias identificados com tipo de ocorrência = 9 (feriado) tiveram seus valores de reservas totais e refeições servidas totais zerados, sob a premissa de que não há demanda real de refeições nesses dias. Esta correção é imprescindível para evitar a contaminação do histórico de demanda com valores irreais e garantir a precisão dos modelos preditivos.

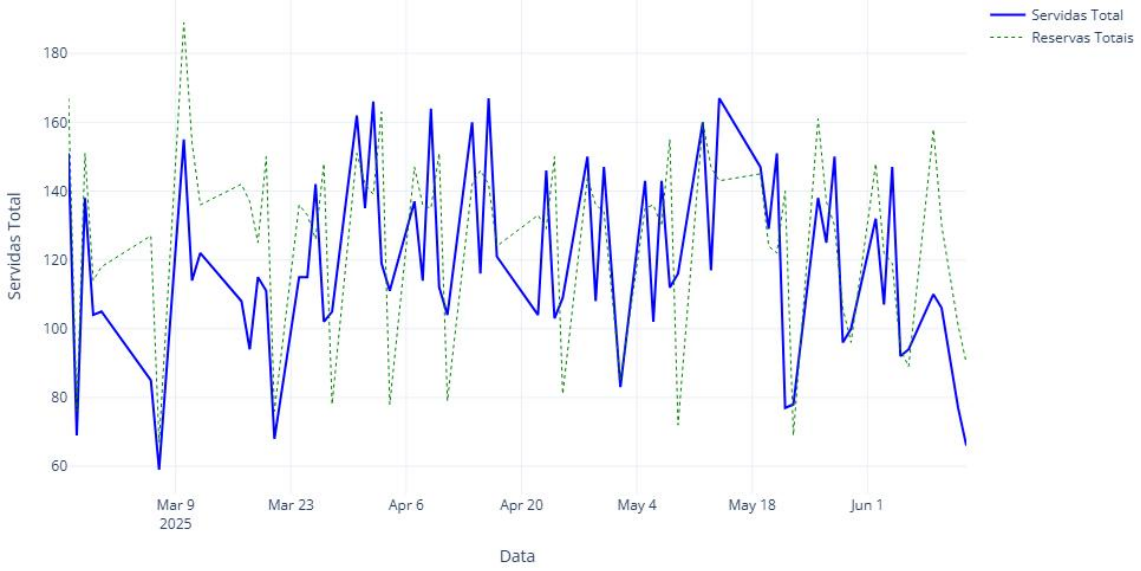
Em seguida, os dados agregados foram separados em df_historico e df_predicao. O df_historico contém os dados até a última data com refeições servidas totais > 0, representando a demanda observada. O df_predicao inclui as datas subsequentes, destinadas à previsão. Uma nova feature, *flag* baixa demanda, foi criada no df_historico para identificar dias em que refeições servidas totais foi menor ou igual a um limiar de 10, o que se mostra útil para análises específicas de eventos de baixa demanda. A natureza interativa e exploratória da gestão do ciclo de vida do modelo justifica a EDA como uma etapa contínua e essencial no processo de pesquisa (IPKOVICH et al., 2024).

4.3 Análise Exploratória de Dados (EDA)

A EDA foi realizada sobre o df_historico e o base_dados (df_historico + df_predicao) para compreender os padrões da demanda de refeições servidas.

A série temporal de refeições servidas totais e reservas totais foi plotada para visualizar a evolução da demanda ao longo do tempo. A figura 1 permitiu identificar visualmente tendências, picos e vales na demanda, assim como a forte relação entre reservas e refeições servidas. A inclusão da *feature flag* baixa demanda no gráfico também auxiliou na identificação de dias com demanda atipicamente baixa. Esta visualização inicial é imprescindível para se entender a dinâmica da demanda e preparar o terreno para análises mais aprofundadas.

Figura 1 Histórico de Demanda e Reservas Totais de Refeições Servidas ao Longo do Tempo



Fonte: Elaboração própria dos autores (2025).

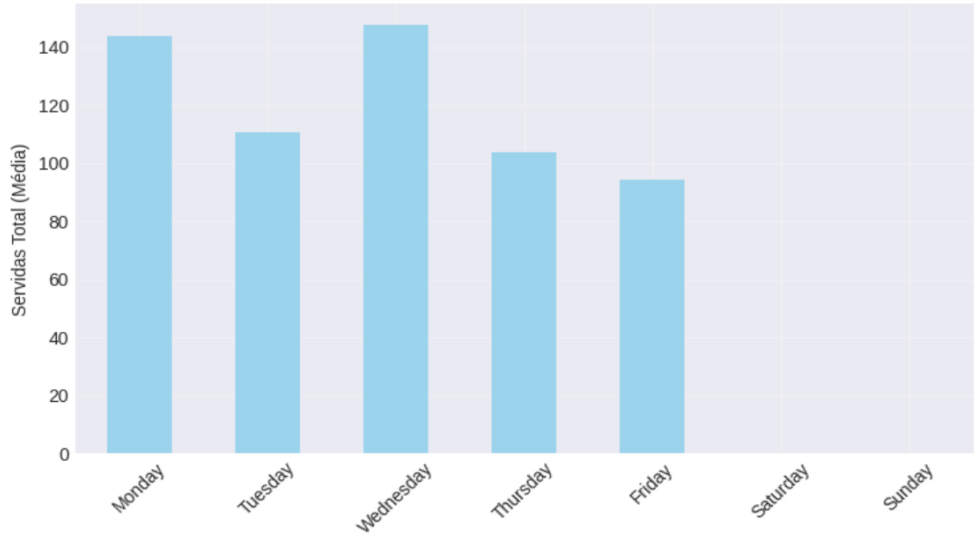
O gráfico demonstra a sazonalidade semanal da demanda (picos e vales recorrentes). A Servidas Total (linha contínua azul) e as Reservas Totais (linha pontilhada verde) apresentam forte correlação visual, validando o uso de reservas como preditor primário. As “reservas” tendem a ser consistentemente maiores que as “servidas”, indicando o volume de não-comparecimento (*no-show*), que é a principal fonte de desperdício a ser modelada.

4.3.1 Padrões Semanais e Distribuição

Para identificar a sazonalidade intrínseca aos dias de operação, a demanda de refeições servidas foi analisada por dia da semana.

O gráfico de barras da Figura 2 exibe a média de refeições servidas por dia da semana, indicando variações significativas. Os dias úteis (Segunda a Sexta-feira) concentram as maiores demandas, com picos notáveis na Segunda e Quarta-feira.

Figura 2 Análise dos Padrões de Demanda por Dia da Semana (Média)

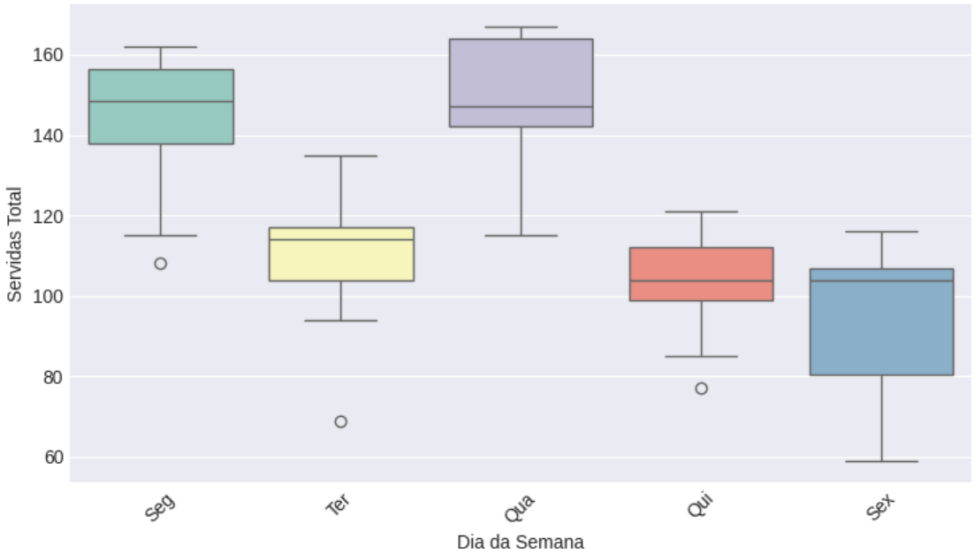


Fonte: Elaboração própria dos autores (2025).

O gráfico demonstra que a demanda média é mais alta no início da semana. A importância do dia da semana como um preditor forte da demanda é um achado consistente com a literatura de previsão em *catering* (MALEFORS et al., 2022).

A distribuição dos dados por dia da semana (Figura 3 - *Boxplot*) complementa a análise anterior, confirmando a alta variabilidade da demanda para cada dia útil.

Figura 3 Análise dos Padrões de Demanda por Dia da Semana (Distribuição)

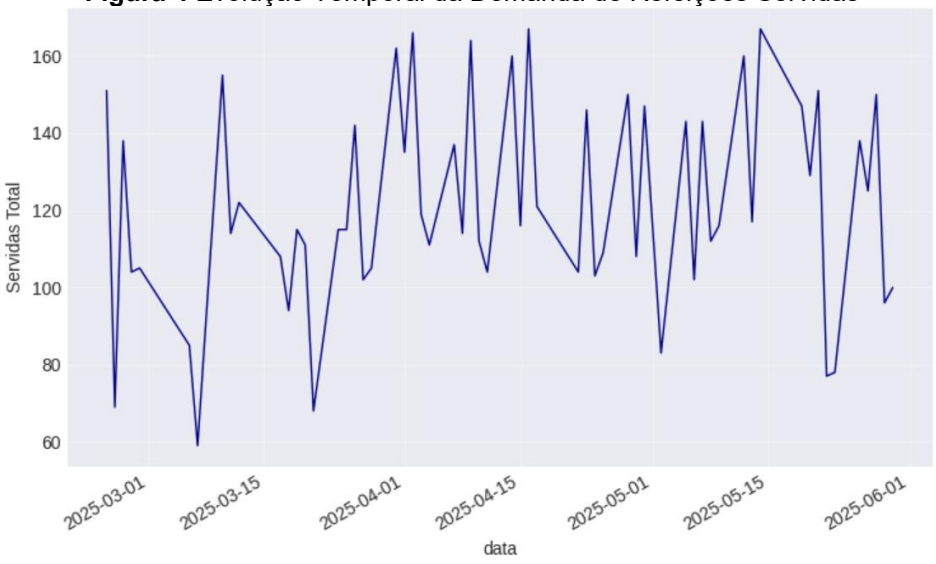


Fonte: Elaboração própria dos autores (2025).

O *boxplot* confirma a grande dispersão dos valores de demanda (variabilidade) nos dias úteis e evidencia a presença de *outliers* (círculos) em alguns dias. Essa variabilidade reforça a necessidade de modelos preditivos que consigam capturar a sazonalidade semanal de forma precisa.

A evolução temporal da série (Figura 4) permitiu uma visualização da tendência geral e das oscilações da demanda ao longo do período analisado (Fevereiro a Junho de 2025). As quedas recorrentes e abruptas para zero ou valores próximos, especialmente nos fins de semana e feriados, reforçam o impacto dos fatores contextuais no consumo.

Figura 4 Evolução Temporal da Demanda de Refeições Servidas

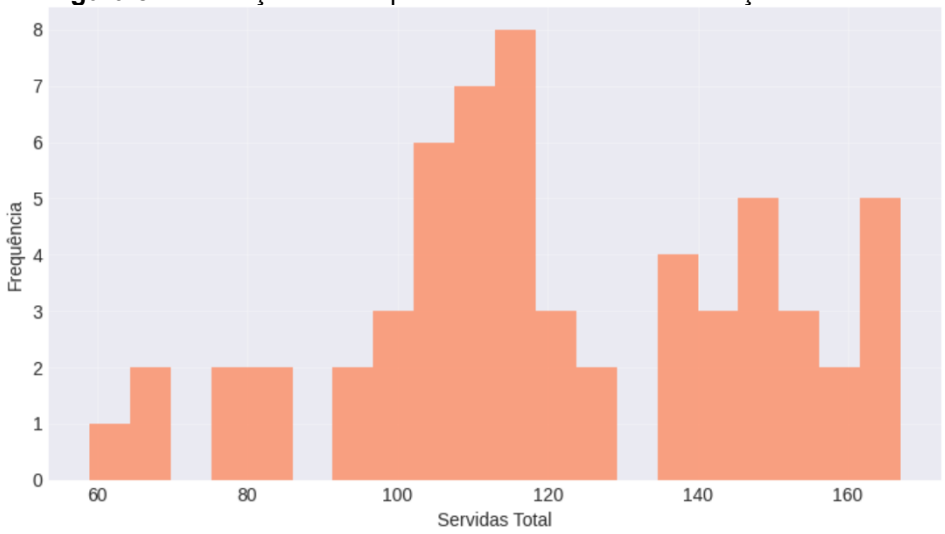


Fonte: Elaboração própria dos autores (2025).

O gráfico demonstra a recorrência de picos e vales (sazonalidade) que refletem o padrão semanal de demanda, interrompido por períodos de recesso (Junho) e dias de demanda zero, o que sublinha a importância de modelar o tempo e os eventos acadêmicos.

Além disso, a distribuição de frequência dos valores (Figura 5 - Histograma) demonstrou que a demanda se concentra em dois picos principais, o que reflete a clara separação entre os dias de operação normal e os dias sem demanda, sendo um dado importante para a escolha de modelos de previsão.

Figura 5 Distribuição de Frequência da Demanda de Refeições Servidas



Fonte: Elaboração própria dos autores (2025).

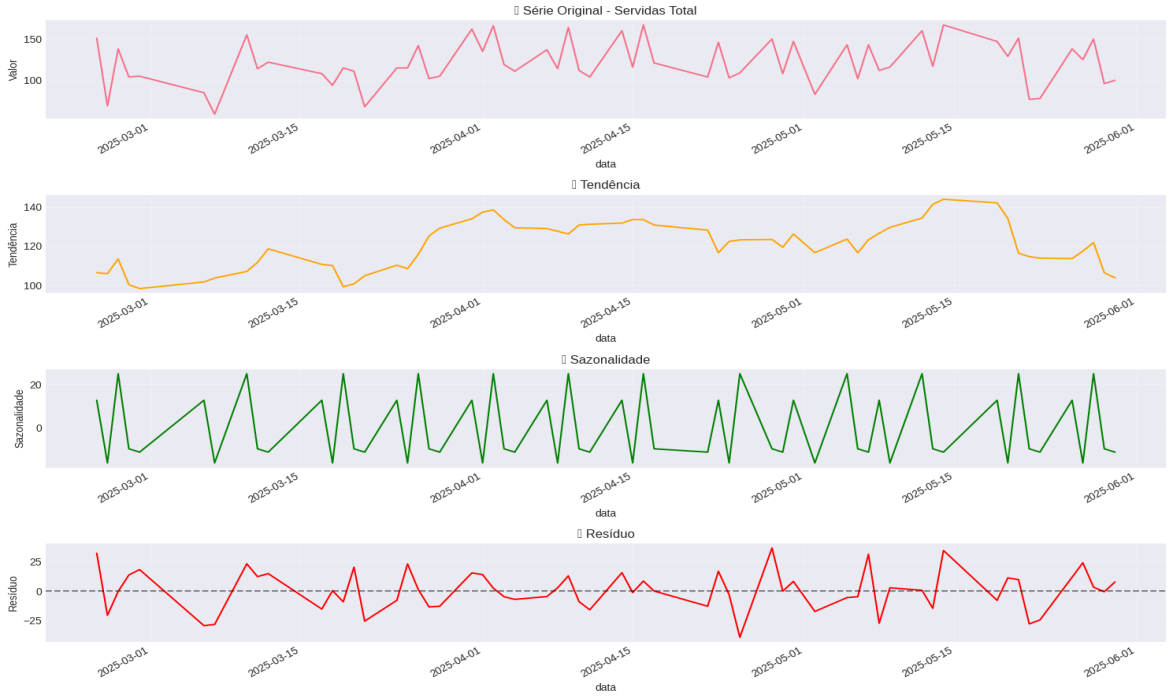
O histograma revela a natureza bimodal da demanda, com um pico em valores próximos a zero (anterior à filtragem) e um segundo pico na faixa de 100 a 160 refeições. Essa característica bimodal indica a presença de dois regimes de demanda distintos (dias letivos vs. não letivos) que os modelos de Machine Learning precisarão aprender a diferenciar.

4.3.2 Decomposição da Série Temporal

Para analisar os componentes estruturais da demanda com maior profundidade, a série temporal de refeições servidas totais (após a filtragem de demanda zero) foi submetida à decomposição sazonal. A identificação de variáveis-chave, como o dia da semana, e a análise de suas interações constitui um aspecto central da EDA, sendo primordial para o desenvolvimento de modelos de ML eficazes (HU et al., 2024). A série temporal foi submetida à decomposição sazonal utilizando os modelos aditivo e multiplicativo.

O primeiro passo foi a aplicação do Modelo Aditivo (Figura 6), que resultou em um R^2 de 60% e um MAPE (Erro Percentual Médio) de 12,44%. Embora essas métricas iniciais sugiram um ajuste razoável, uma análise mais aprofundada dos resíduos, detalhada posteriormente, indicou que o modelo não capturava adequadamente toda a estrutura da série temporal.

Figura 6 Decomposição da Série Temporal de Refeições Servidas Totais (Modelo Aditivo)

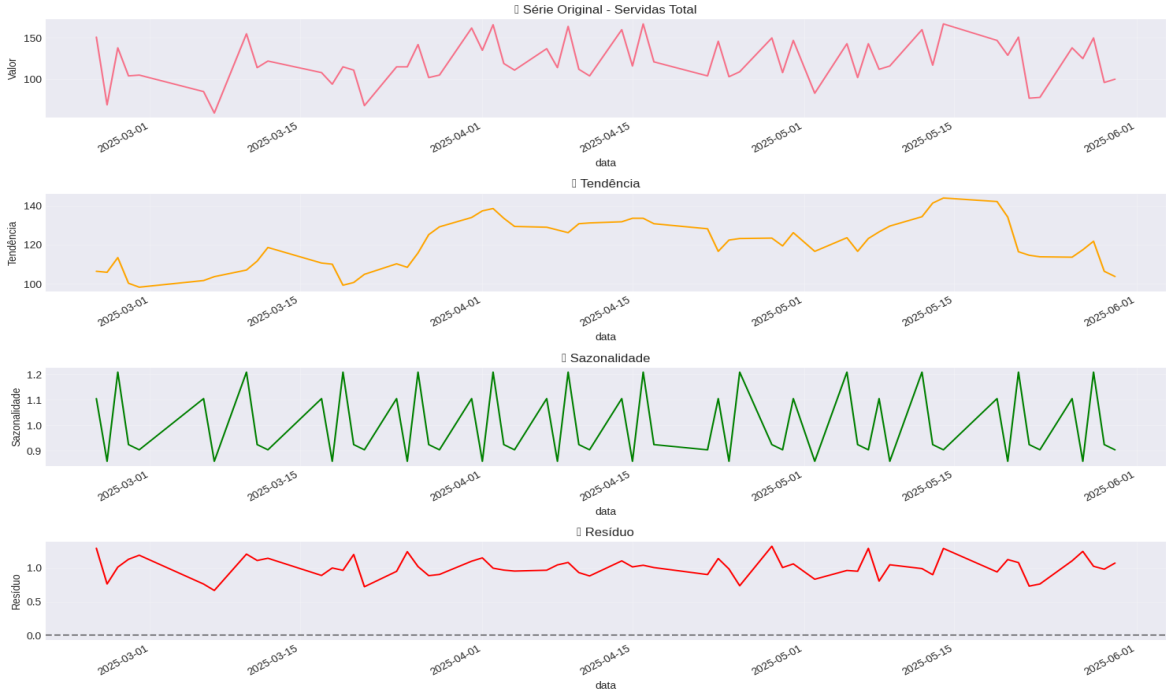


Fonte: Elaboração própria dos autores (2025).

A Figura 6 separa a série original (gráfico superior) em seus componentes. A Tendência (linha amarela) mostra a evolução suave da demanda, e a Sazonalidade (linha verde) exibe o padrão semanal constante. Os Resíduos (linha azul) mostram a variância não explicada, que, no modelo aditivo, é alta, como indicado pelo desvio padrão de 17.18.

Em seguida, explorou-se o Modelo Multiplicativo (Figura 7), que obteve um R2 de 59% e um MAPE (Erro Percentual Médio) de 12.49%, demonstrando um ajuste superior em comparação ao modelo aditivo.

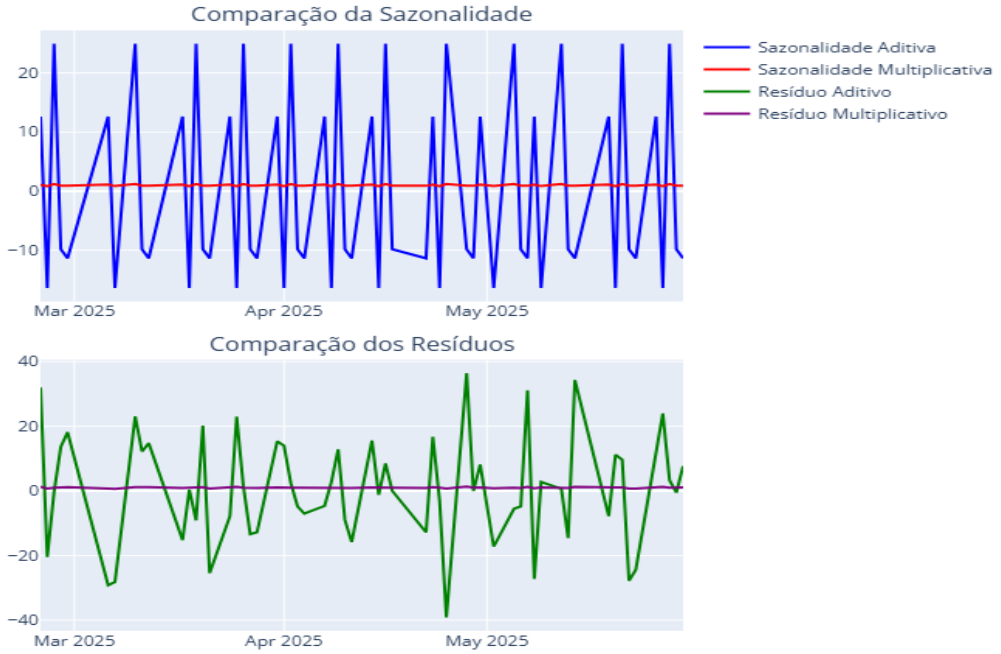
Figura 7 Decomposição da Série Temporal de Refeições Servidas Totais (Modelo Multiplicativo)



Fonte: Elaboração própria dos autores (2025).

Na Figura 7, a Sazonalidade (fator - linha verde) oscila em torno da média 1.0, indicando a proporcionalidade da variação semanal em relação à tendência. A dispersão dos Resíduos (gráfico inferior) é significativamente mais estreita, com desvio padrão de 15%, confirmando que a sazonalidade e a tendência capturam melhor a variância da série do que o modelo aditivo..

Figura 8 Comparação de Métricas de Decomposição (Modelos Aditivo e Multiplicativo)



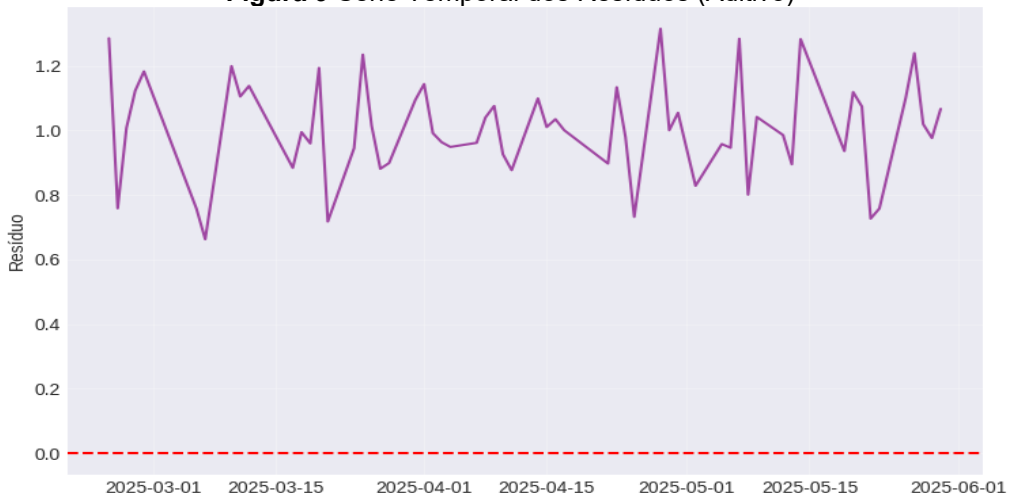
Fonte: Elaboração própria dos autores (2025).

A Figura 8 apresenta a comparação visual da Sazonalidade e dos Resíduos de ambos os modelos, confirmando que, na série filtrada, eles performam de maneira similar, validando a premissa de que a abordagem de previsão deve lidar com a sazonalidade como um fator proporcional à demanda média. Essa conclusão reforça a necessidade de explorar modelos de ML mais sofisticados, como *Random Forest* e *Gradient Boosting*, capazes de capturar tanto a sazonalidade quanto as relações não lineares complexas entre as variáveis (TURKER, 2025).

4.3.3 Análise de Resíduos - Modelo Aditivo

A análise dos resíduos é uma etapa crítica para avaliar a qualidade e a adequação do modelo de decomposição escolhido. O estudo prosseguiu com a inspeção detalhada dos resíduos gerados pelo Modelo Aditivo, buscando validar a suposição de que o modelo eliminou a estrutura da série temporal, deixando apenas ruído branco.

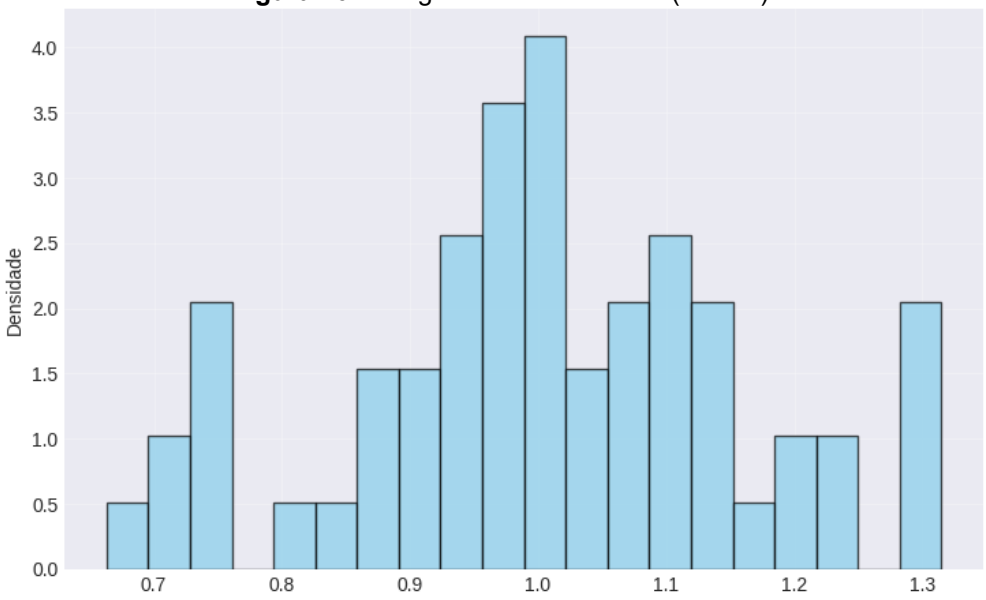
Figura 9 Série Temporal dos Resíduos (Aditivo)



Fonte: Elaboração própria dos autores (2025).

A Série Temporal dos Resíduos do Modelo Aditivo (Figura 9) ilustra a variância não explicada pelo modelo. Visualmente, esta série apresenta flutuações amplas e descontroladas, com um desvio padrão de 17.18, confirmando que o modelo aditivo não conseguiu capturar adequadamente toda a complexidade da estrutura da demanda.

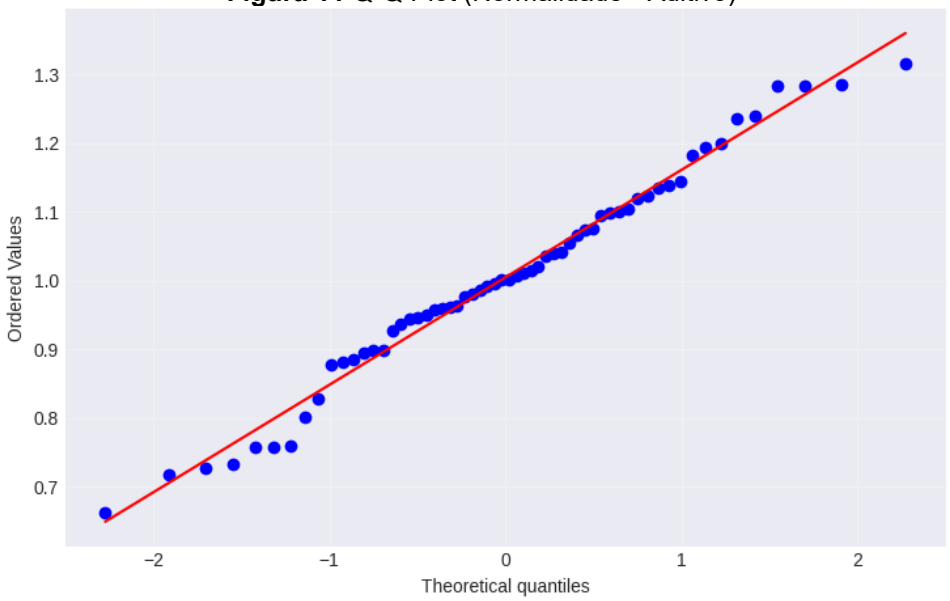
Figura 10 Histograma dos Resíduos (Aditivo)



Fonte: Elaboração própria dos autores (2025).

O Histograma dos Resíduos (Figura 10) exibe a distribuição de frequência dos erros. Embora o centro da distribuição se localize próximo a zero, indicando que o modelo não possui viés significativo, a dispersão é ampla, refletindo a grande variabilidade dos erros de previsão.

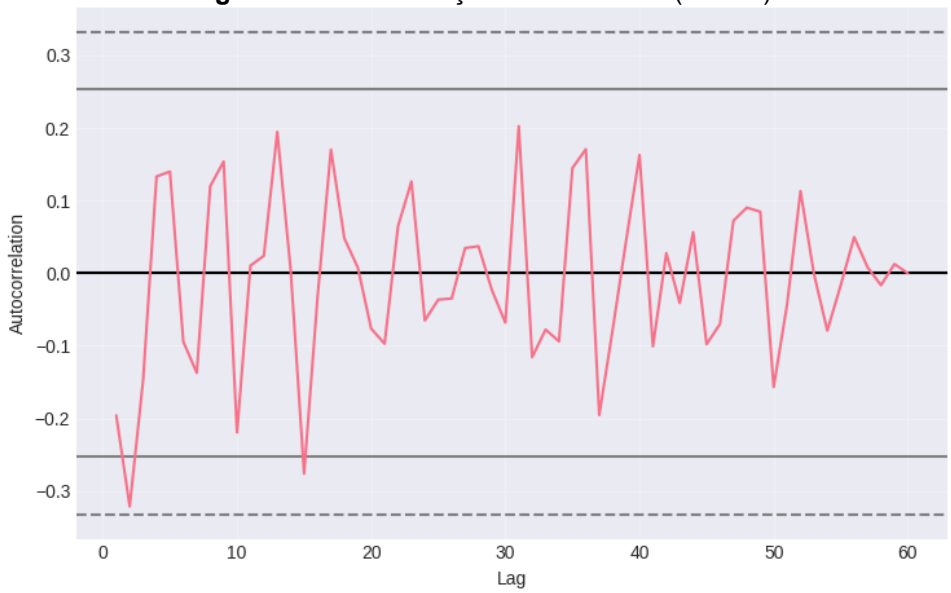
Figura 11 Q-Q Plot (Normalidade - Aditivo)



Fonte: Elaboração própria dos autores (2025).

O Q-Q Plot (Figura 11) é uma ferramenta para verificar se os resíduos seguem uma distribuição normal. A análise mostrou que, embora a hipótese de normalidade não tenha sido estritamente rejeitada, as extremidades (*outliers*) se desviam da linha reta, sugerindo que a adequação à suposição de normalidade não é perfeita.

Figura 12 Autocorrelação dos Resíduos (Aditivo)



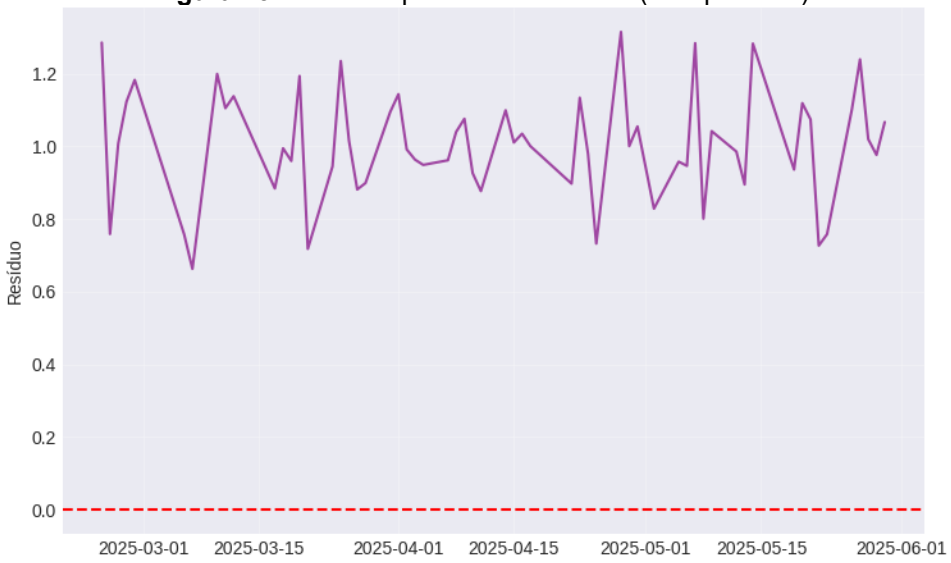
Fonte: Elaboração própria dos autores (2025).

Ainda sobre a análise de resíduos do modelo aditivo, o gráfico de Autocorrelação dos Resíduos (Figura 12) indica a presença de autocorrelação nos primeiros *lags* (valores fora das linhas tracejadas de intervalo de confiança). Esta autocorrelação remanescente é uma evidência de que a estrutura da série não foi totalmente capturada pelo modelo aditivo, indicando a necessidade de uma abordagem alternativa (MONTGOMERY et al., 2021).

4.3.4 Análise de Resíduos - Modelo Multiplicativo

A análise dos resíduos do Modelo Multiplicativo demonstrou um ajuste superior para a série de demanda.

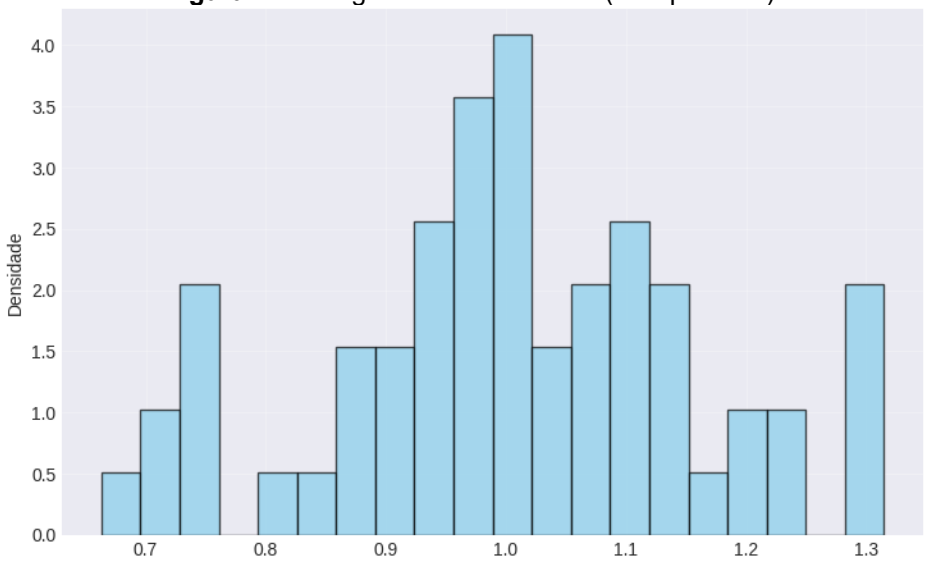
Figura 13 Série Temporal dos Resíduos (Multiplicativo)



Fonte: Elaboração própria dos autores (2025).

A Série Temporal dos Resíduos do Modelo Multiplicativo (Figura 13) exibe flutuações visivelmente mais estreitas, com um desvio padrão de 15%. Essa redução significativa na dispersão da variância não explicada comprova que o modelo multiplicativo foi mais eficaz ao modelar a sazonalidade como um fator proporcional à tendência da demanda.

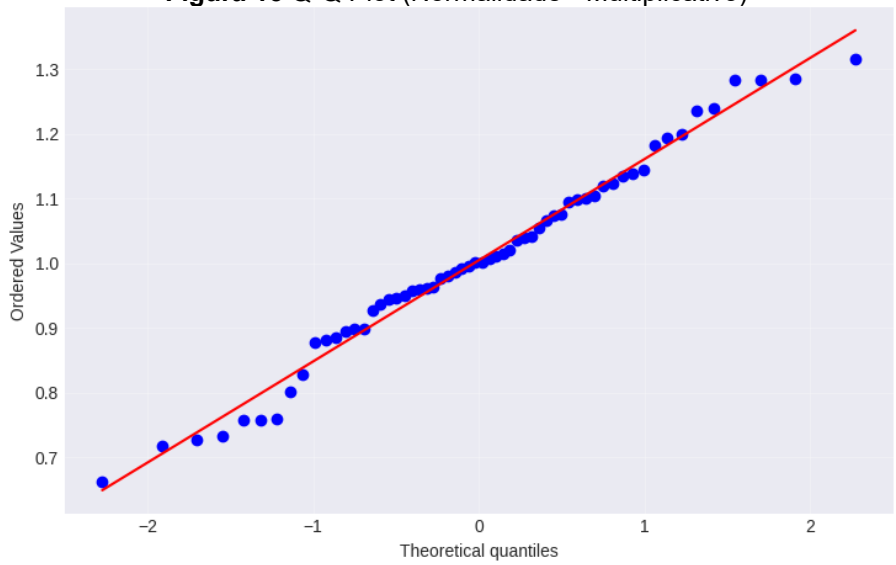
Figura 14 Histograma dos Resíduos (Multiplicativo)



Fonte: Elaboração própria dos autores (2025).

O Histograma dos Resíduos (Figura 14) apresenta uma distribuição mais concentrada em torno do valor 1.0 (o resíduo em um modelo multiplicativo é um fator, e não um erro aditivo próximo a zero). Esta concentração reforça o melhor ajuste do modelo.

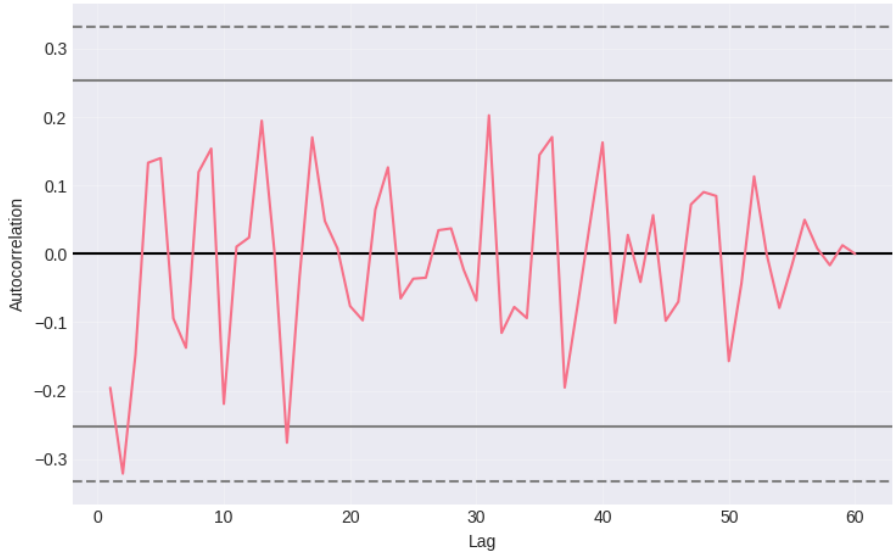
Figura 15 Q-Q Plot (Normalidade - Multiplicativo)



Fonte: Elaboração própria dos autores (2025).

O Q-Q Plot (Figura 15) mostra que os pontos se alinham de maneira ainda mais coesa à linha reta, confirmando que os resíduos do modelo multiplicativo estão bem próximos de uma distribuição normal.

Figura 16 Autocorrelação dos Resíduos (Multiplicativo)



Fonte: Elaboração própria dos autores (2025).

O gráfico de Autocorrelação dos Resíduos (Figura 16) do modelo multiplicativo é o mais importante para validar o ajuste: a maioria dos *lags* permanece dentro das faixas de confiança, indicando que o padrão de resíduos se aproxima muito mais do ruído branco do que no modelo aditivo. Essa validação reforça a conclusão de que a escolha do modelo multiplicativo foi mais apropriada para a complexidade desta série temporal de demanda, justificando o foco em modelos mais avançados de Machine Learning para as próximas etapas (TURKER, 2025).

5 Lições aprendidas

A execução da EDA e das etapas de pré-processamento para a previsão da demanda de refeições em uma instituição de ensino gerou lições valiosas para o aprimoramento contínuo deste projeto e para futuras iniciativas na área de sustentabilidade e ML.

1. **A Qualidade e Integridade dos Dados são Inegociáveis:** A validação rigorosa dos dados brutos, incluindo a verificação de estrutura, tipos e regras de negócio, destacou a importância de um *dataset* limpo e consistente. Problemas como valores nulos em colunas críticas ou inconsistências entre refeições servidas e reservadas podem comprometer seriamente a acurácia dos modelos preditivos. A experiência reforça a premissa de que a eficácia da Inteligência Artificial (IA) depende da disponibilidade de grandes volumes de dados de alta qualidade (KANWAL et al., 2025). A gestão de dados é imprescindível, especialmente diante do crescente volume de informações (HU et al., 2024).
2. **A Agregação e Enriquecimento de Dados Ampliam o Poder Preditivo:** A agregação dos dados para granularidade diária e a integração de *features* de cardápio e informações meteorológicas foram passos decisivos. A literatura corrobora que a inclusão de variáveis adicionais, como o histórico de presenças de alunos, previsões climáticas, períodos de provas e calendário escolar, é essencial para aprimorar a precisão das previsões de demanda (SOUZA; ORSI, 2024; RODRIGUES et al., 2024). A capacidade de extrair e gerar variáveis não diretamente relacionadas ao serviço de alimentação (como dia da semana, mês, feriados, temperatura e precipitação) provou ser um diferencial.
3. **Sazonalidade e Padrões Semanais são Predominantes:** A análise de padrões semanais, com picos de demanda em dias úteis e quedas em feriados ou fins de semana, demonstrou a forte sazonalidade dos dados. O dia da semana emergiu como um dos fatores mais importantes para a acurácia da previsão (MALEFORS et al., 2022), reforçando a necessidade de considerar esses padrões no desenvolvimento de modelos.
4. **A Decomposição Sazonal Exige uma Escolha Crítica do Modelo:** A EDA inicial forneceu *insights* valiosos, mas a performance modesta do modelo aditivo (R^2 de 60%) ressaltou a complexidade da série. A comparação entre os modelos foi crucial: embora o MAPE do modelo multiplicativo (12,49%) tenha sido marginalmente superior ao do aditivo (12,44%), a sua escolha se validou pela drástica redução na variância dos resíduos. Isso demonstrou que a abordagem multiplicativa captura a natureza da sazonalidade proporcional de forma muito mais eficaz, sendo determinante para o desenvolvimento de modelos de ML mais sofisticados e precisos para cenários dinâmicos.
5. **A Necessidade de um Olhar Multivariado na EDA:** A correlação entre variáveis, como reservas e taxa de consumo, é um indicativo da complexidade da demanda. Estudos mostram que fatores como a variedade do menu, contagens, receita, mobilidade no campus e temperatura influenciam efetivamente as preferências alimentares (TURKER, 2025). A EDA é uma ferramenta poderosa para visualizar essas relações e subsidiar a seleção de features mais relevantes para os modelos de ML, abordando os desafios de problemas de otimização multiobjetivo (HU et al., 2024).
6. **Desafios na Coleta de Dados e Generalização:** A experiência com restrições de dados, como as enfrentadas durante a COVID-19 em estudos semelhantes (KODORS et al., 2022), ou a dependência de amostras limitadas (BYKER SHANKS

et al., 2023), destaca a importância de estratégias robustas de coleta e a cautela na generalização dos resultados. A necessidade de grandes conjuntos de dados rotulados é um desafio chave para o ML, com o risco de *overfitting* em amostras pequenas (WILLIAMS et al., 2025).

Em suma, a EDA é uma etapa exploratória e iterativa (IPKOVICH et al., 2024) que não apenas revelou padrões importantes na demanda de refeições, mas também sublinhou a necessidade de aprimorar a coleta e o enriquecimento de dados e de explorar modelos de ML mais avançados para construir um sistema de previsão mais preciso e robusto. As lições aprendidas apontam para a importância de uma abordagem holística, que combine técnicas de análise de dados com o conhecimento do domínio para enfrentar o complexo problema do desperdício alimentar.

6 Considerações finais

O presente relato técnico aprofundou-se na EDA como um pilar essencial para o desenvolvimento de um sistema de previsão da demanda de refeições em uma instituição de ensino, visando a mitigação do desperdício alimentar e a promoção da sustentabilidade. A problemática do desperdício, reconhecida globalmente e amplificada em contextos educacionais, exige soluções inovadoras e baseadas em dados para otimizar a gestão de recursos e garantir a segurança alimentar.

A implementação da EDA, desde a validação e o pré-processamento dos dados brutos até a análise de padrões temporais e correlações, revelou muitos *insights*. A integração de features de cardápio e informações meteorológicas, bem como a correção de dados para dias de feriado, demonstrou a importância de um *dataset* enriquecido e de alta qualidade para qualquer esforço de modelagem preditiva. A robustez da gestão de dados é primordial, especialmente no cenário de explosão informacional (HU et al., 2024).

Os resultados da EDA confirmaram a forte sazonalidade semanal da demanda de refeições, com o dia da semana emergindo como um preditor significativo. A comparação entre modelos de decomposição sazonal demonstrou a complexidade da série, mas validou uma abordagem que lida com a sazonalidade como um fator proporcional à demanda média. Essa conclusão reforça a necessidade de empregar técnicas de ML mais avançadas, como *Random Forest* ou *XGBoost*, capazes de capturar relações não lineares e múltiplos fatores influenciadores, superando métodos convencionais (WICAKSONO et al., 2025; CHAUDHARI et al., 2025).

As lições aprendidas neste estudo enfatizam que a precisão das previsões de demanda é diretamente proporcional à qualidade, integridade e diversidade das variáveis incluídas na análise. Fatores como a variedade do menu, condições climáticas, eventos no campus e o histórico de reservas e consumo são elementos críticos para aprimorar a acurácia dos modelos (SOUZA; ORSI, 2024; TURKER, 2025). A contínua busca por aprimoramentos e o investimento em tecnologias e ferramentas que promovam uma gestão de recursos mais responsável e sustentável são imprescindíveis para transformar os desafios do desperdício alimentar em oportunidades para um ambiente educacional mais eficiente e equitativo.

Por fim, este trabalho reforça o papel da EDA como um processo contínuo e iterativo que fornece a inteligência necessária para o desenvolvimento de soluções baseadas em ML. A exploração de variáveis contextuais, comportamentais e sociodemográficas, conforme sugerido pela literatura (LONSKA et al., 2025; STACCHINI et al., 2024), representa o próximo passo para construir modelos preditivos de demanda mais robustos e explicáveis. Ao integrar a inteligência humana com a capacidade analítica

da máquina, torna-se possível otimizar a gestão alimentar, reduzir o desperdício e caminhar em direção a um futuro mais sustentável nas instituições de ensino.

Referências

BEZERRA, M. S. et al. **Insegurança alimentar e nutricional no Brasil e sua correlação com indicadores de vulnerabilidade**. Revista Ciência & Saúde Coletiva, 2024. Disponível em: https://www.scielo.br/j/csc/a/vpGZNFNcKySWVrVy4KR3Gtc/. Acesso em: 20 set. 2025.

BYKER SHANKS, C. et al. **School Lunch Advisory Councils' use of behavioural economics influences vegetable selection and waste**. Health Education Journal, v. 82, 2023.

CHAUDHARI, M. A. et al. **Forecasting and Modelling of Food Demand Supply Chain using Machine Learning**. International Journal of Innovative Research in Multidisciplinary Portable Systems (IJIRMPS), v. 13, 2025.

ELNAKIB, S. A. et al. **Food Waste in Schools: A Pre-/Post-Test Study Design Examining the Impact of a Food Service Training Intervention to Reduce Food Waste**. International Journal of Environmental Research and Public Health, v. 18, 2021.

FAO. (2021). Food waste Index Report. Roma: FAO. Disponível em: https://www.unep.org/resources/report/unep-food-waste-index-report-2021. Acesso em: 15 set. 2025.

GUNDERS, D. **Waste Free Kitchen Handbook: A Guide to Reducing Food Waste, Saving Money, and Eating Better**. New York: Ten Speed Press, 2012.

HU, J. et al. **Design of information management model based on multiobjective optimization algorithm in intelligent electric financial system**. PeerJ Computer Science, v. 10, 2024.

IPKOVICH, Á. et al. **Network science and explainable AI-based life cycle management of sustainability models**. PLoS ONE, v. 19, 2024.

KANWAL, N. et al. **Revolutionizing food safety in the airline industry: AI-powered smart solutions**. Trends in Food Science & Technology, v. 159, 2025.

KODORS, S. et al. **Plate Waste Forecasting Using the Monte Carlo Method for Effective Decision Making in Latvian Schools**. Nutrients, v. 14, 2022.

LONSKA, J. et al. **Reducing Plate Waste in Latvian Schools: Evaluating Interventions to Promote Sustainable Food Consumption Practices**. Foods, v. 14, 2025.

MALEFORS, C. et al. **Food waste reduction and economic savings in times of crisis: The potential of machine learning methods to plan guest attendance in Swedish public catering during the Covid-19 pandemic**. Socio-Economic Planning Sciences, v. 82, 2022.

MONTGOMERY, D. C.; PECK, E. A.; VINING, G. **Introduction to Linear Regression Analysis**. New York: Wiley, 2021.

RODRIGUES, M. et al. **Machine learning models for short-term demand forecasting in food catering services: A solution to reduce food waste**. Journal of Cleaner Production, v. 435, 2024.

SOUZA, M. S.; ORSI, R. N. **Sustentabilidade na Mesa: redução do desperdício alimentar em uma instituição de ensino com previsão de demanda por aprendizado de máquina**. Revista H-Tec Humanidades e Tecnologia, v. 11, 2024, Ed. Especial XIX SIMPROFI.

STACCHINI, L. et al. **Association Between Socio-Demographic Characteristics and Household Food Waste Behaviors Among University Students in Italy: The UniFoodWaste Study**. Sustainability, v. 16, 2024.

TURKER, G. F. **Reducing Food Waste in Campus Dining: A Data-Driven Approach to Demand Prediction and Sustainability**. Sustainability, v. 17, 2025.

WICAKSONO, T. et al. **Customer-centric circular economy as-a-service decision-making: Machine learning-driven open innovation in food service**. Cleaner Environmental Systems, v. 18, 2025.

WILLIAMS, L. et al. **Measuring the Level of Aflatoxin Infection in Pistachio Nuts by Applying Machine Learning Techniques to Hyperspectral Images**. Sensors, v. 25, 2025.