1. Introdução

O planejamento diário da produção de refeições em restaurantes escolares envolve uma decisão operacional sob incerteza. Produzir abaixo da demanda compromete o atendimento aos estudantes; produzir acima da demanda amplia sobras, custos e desperdício. Esse problema torna-se mais sensível quando a decisão depende de reservas, consumo observado manualmente, calendário acadêmico, cardápio e variações de rotina institucional.

Em serviços de alimentação coletiva, a previsão de demanda pode apoiar a redução de desperdício e melhorar a alocação de recursos, desde que os dados utilizados sejam rastreáveis e adequados ao contexto operacional. A literatura recente mostra que modelos de aprendizado de máquina podem melhorar estimativas de curto prazo quando combinam histórico, calendário e variáveis contextuais (RODRIGUES et al., 2024; TURKER, 2025). Entretanto, a escolha do algoritmo não resolve, por si só, problemas de qualidade, ausências, duplicidades e mudança de comportamento ao longo do tempo.

Este artigo apresenta o desenvolvimento e a avaliação de um artefato de dados e decisão para apoiar a previsão de demanda em um restaurante escolar. O artefato foi estruturado em camadas de ingestão, consolidação, engenharia de atributos, modelagem preditiva e política de margem de segurança. A contribuição central está na integração entre preparação rastreável dos dados, validação temporal e avaliação operacional por métricas de sobra, falta e nível de atendimento.

O objetivo do estudo é desenvolver um artefato computacional de apoio ao planejamento da produção de refeições, comparando o planejamento baseado exclusivamente em reservas com abordagens preditivas adaptativas e políticas de margem de segurança. O estudo também discute a aderência do problema aos Objetivos de Desenvolvimento Sustentável, especialmente o ODS 2, relacionado à segurança alimentar, e o ODS 12, voltado ao consumo e produção responsáveis.

2. Referencial teórico

2.1 Previsão de demanda e desperdício em alimentação coletiva

O desperdício de alimentos em serviços institucionais decorre, em parte, do desalinhamento entre produção planejada e consumo real. Malefors (2022) destaca que a relação entre quantidade preparada e número efetivo de usuários atendidos é um fator relevante na geração de perdas em alimentação coletiva. Rodrigues et al. (2024) reforçam que previsões de curto prazo podem reduzir superprodução e demanda não atendida quando incorporadas ao processo de planejamento.

No contexto escolar, a demanda pode variar por dia da semana, período letivo, feriados, avaliações, clima e atratividade do cardápio. Turker (2025) discute restaurantes universitários como ambientes nos quais dados históricos e variáveis institucionais podem apoiar decisões sustentáveis. Kim et al. (2023), ao explorarem dados de cafeteria, também indicam que informações textuais de cardápio podem carregar sinais úteis para a previsão de presença e consumo.

2.2 *Design Science Research* e artefatos de dados

A pesquisa foi orientada pela *Design Science Research*, abordagem adequada quando o objetivo é construir e avaliar um artefato voltado à solução de um problema prático. Hevner et al. (2004) caracterizam a pesquisa em design como a criação de artefatos capazes de ampliar capacidades humanas e organizacionais. Peffers et al. (2007) propõem um processo

que envolve identificação do problema, definição de objetivos, design, desenvolvimento, demonstração, avaliação e comunicação.

Neste estudo, o artefato não é apenas o modelo preditivo, mas o fluxo analítico que torna a modelagem operacionalmente defensável. A separação entre dados brutos, dados consolidados e bases analíticas reduz a opacidade do processo, preserva critérios de imputação e evita que falhas de coleta sejam confundidas com comportamento real de demanda. Esse cuidado está alinhado à preocupação de Tripathi et al. (2021) com robustez e confiabilidade em modelos orientados por dados.

2.3 Métricas preditivas e indicadores operacionais

A avaliação do artefato combina métricas estatísticas e indicadores operacionais. O MAE expressa o erro absoluto médio em refeições; o RMSE penaliza com maior intensidade dias com erros elevados; e o WAPE apresenta o erro absoluto em relação ao volume real observado. Chai e Draxler (2014) discutem diferenças entre métricas de erro e destacam que a escolha da métrica deve considerar o objetivo da aplicação.

Além das métricas preditivas, foram calculadas sobra média, falta média, dias com falta, nível de atendimento e custo operacional equivalente. Essa distinção é necessária porque o menor erro estatístico nem sempre representa a melhor decisão operacional. Em restaurantes escolares, a falta de refeições possui impacto operacional mais crítico que a sobra, mas a redução de faltas não pode gerar produção excessiva sem controle.

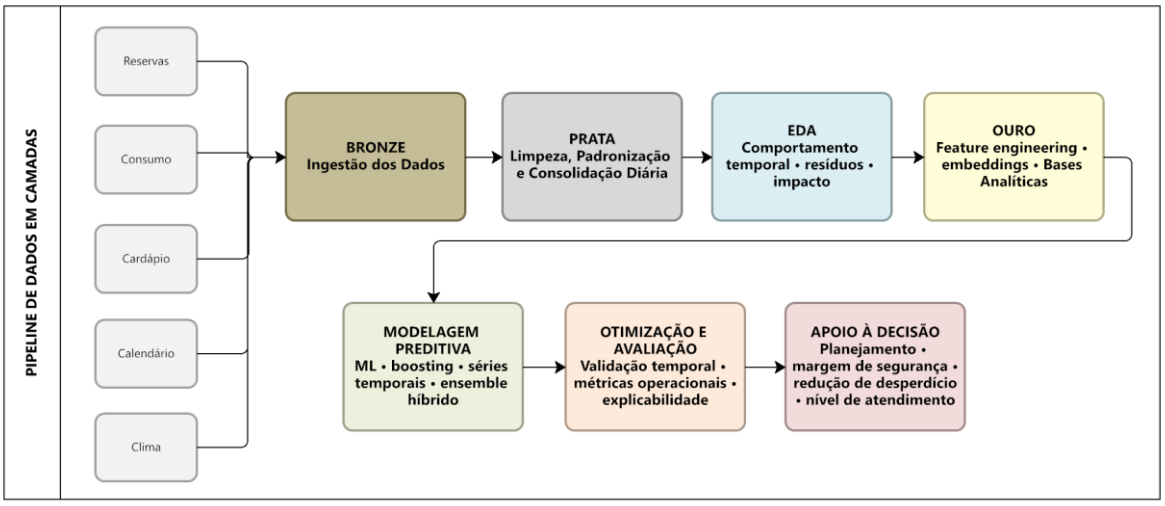
3. Metodologia

3.1 Delineamento da pesquisa

A pesquisa possui natureza aplicada e exploratória, orientada pela construção de um artefato de apoio à decisão. O caso analisado corresponde a um restaurante escolar com registros de reservas, consumo, cardápio, calendário acadêmico e clima no período de 2023 a 2025. A unidade de análise adotada foi diária, pois a decisão operacional de produção é tomada para cada dia de atendimento.

O fluxo metodológico foi organizado em camadas para separar responsabilidades e reduzir a opacidade do processo analítico. A camada Bronze preservou as fontes ingeridas; a camada Prata consolidou os dados em granularidade diária; e a camada Ouro reuniu atributos preditivos para modelagem. Após a análise exploratória e a engenharia de atributos, foram avaliados modelos preditivos e políticas de margem de segurança. A Figura 1 sintetiza esse encadeamento, desde as fontes operacionais até a etapa de apoio à decisão.

Figura 1 - Pipeline de dados em camadas do artefato



A Figura 1 evidencia que o artefato não se limita ao treinamento de modelos preditivos. O processo inicia com fontes heterogêneas, como reservas, consumo, cardápio, calendário e clima, e avança por etapas de ingestão, limpeza, padronização, análise exploratória, engenharia de atributos e modelagem. Essa organização permite rastrear a origem das variáveis utilizadas e conectar a previsão de demanda às decisões operacionais de planejamento, margem de segurança, redução de desperdício e nível de atendimento.

3.2 Preparação dos dados

A ingestão contemplou cinco domínios: reservas, consumo, cardápio, calendário e clima. Ao final da ingestão, foram preservados 84.453 registros de reservas, 66.869 registros de consumo, 1.095 registros de cardápio, 1.096 observações de calendário e 1.096 observações climáticas. Os arquivos brutos de consumo continham duplicidades e sobreposições entre fontes; por isso, a deduplicação por aluno e data foi etapa necessária para evitar supercontagem.

A base Prata consolidou as fontes em 1.096 dias de calendário, distinguindo valores observados, estimados e não aplicáveis à modelagem. Reservas e consumos ausentes ou suspeitos foram tratados de forma rastreável, mantendo os valores originais em colunas separadas e registrando critérios de modelagem. A base Ouro resultou em 548 registros modeláveis e 140 atributos, incluindo reservas, defasagens, médias móveis, calendário, clima e categorias de cardápio.

Tabela 1 - Síntese das camadas do artefato de dados

Camada	Finalidade	Resultado principal
Bronze	Preservar fontes ingeridas com mínima transformação.	Reservas, consumo, cardápio, calendário e clima em formatos auditáveis.
Prata	Consolidar granularidade diária e critérios de qualidade.	1.096 dias com separação entre observado, estimado e modelável.
Ouro	Gerar atributos para modelagem preditiva.	548 registros modeláveis e 140 atributos preditivos.

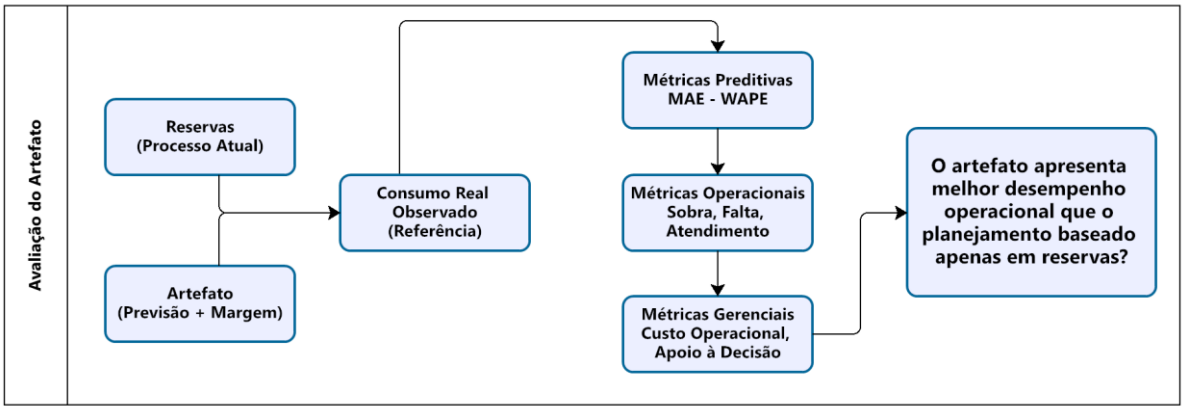
3.3 Modelagem, validação temporal e margem

Foram avaliadas abordagens lineares, modelos baseados em árvores, modelos de boosting, séries temporais, ensembles e experimentos adaptativos. A validação respeitou a ordem temporal, evitando divisão aleatória dos dados. Como a análise anual indicou mudança

de comportamento entre 2023, 2024 e 2025, foram testadas janelas expansivas, janelas móveis e ponderação por recência.

A margem de segurança foi recalibrada sobre os melhores modelos adaptativos para transformar previsões pontuais em recomendações operacionais de produção. As políticas testadas incluíram margens fixas, quantis de erro positivo, margens por dia da semana, por mês, por faixa de previsão e combinações contextuais com tetos percentuais. A Figura 2 apresenta a lógica de avaliação adotada para comparar o planejamento atual baseado apenas em reservas com o artefato proposto, considerando tanto métricas preditivas quanto indicadores operacionais.

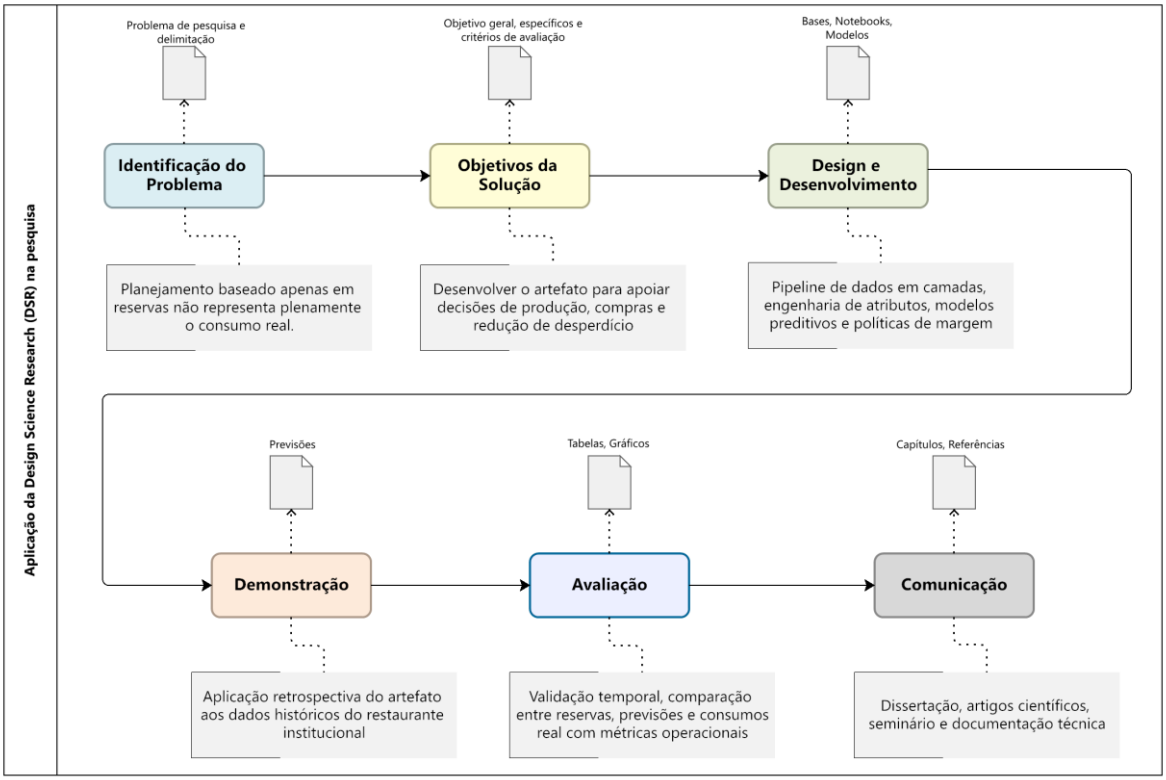
Figura 2 - Lógica de avaliação do artefato



A Figura 2 mostra que a avaliação do artefato não foi baseada apenas na proximidade estatística entre previsão e consumo real. Além de métricas como MAE e WAPE, foram considerados indicadores diretamente ligados à operação do restaurante escolar, como sobra, falta, nível de atendimento e custo operacional equivalente. Essa estrutura permite verificar se a recomendação de produção melhora o processo decisório em relação ao uso exclusivo das reservas, sem confundir desempenho preditivo com desempenho operacional.

A aplicação da Design Science Research foi operacionalizada de forma integrada ao ciclo de desenvolvimento do artefato. A identificação do problema partiu da diferença entre reservas e consumo real; os objetivos da solução foram definidos a partir da necessidade de apoiar produção, compras e redução de desperdício; e o desenvolvimento foi materializado em bases analíticas, rotinas computacionais, modelos e políticas de margem. A demonstração utilizou dados históricos do restaurante escolar, enquanto a avaliação comparou reservas, previsões e consumo real observado.

Figura 3 - Aplicação da Design Science Research na pesquisa



A Figura 3 explicita a correspondência entre as etapas da DSR e as atividades realizadas na pesquisa. A identificação do problema orientou a definição dos objetivos do artefato; o design e desenvolvimento resultaram no pipeline de dados, nos modelos e nas políticas de margem; e a demonstração e avaliação ocorreram por meio da aplicação retrospectiva aos dados históricos. Essa organização reforça que o estudo não se limita a comparar algoritmos, mas avalia um artefato completo de apoio à decisão.

4. Resultados e discussão

4.1 Mudança de comportamento entre anos

A análise anual mostrou que o baseline baseado exclusivamente em reservas não apresentou comportamento estável ao longo dos três anos. Em 2023, reservas e consumo ficaram mais próximos; em 2024 e 2025, o consumo passou a superar as reservas com maior frequência. Esse resultado indica mudança de regime operacional e justifica o uso de validação temporal e estratégias adaptativas.

Na validação entre anos, modelos treinados apenas em 2023 não generalizaram bem para 2024. Por outro lado, ao usar histórico até 2024 para prever 2025, modelos com ponderação por recência melhoraram o desempenho em relação ao baseline. Essa evidência sugere que o artefato deve aprender com o histórico recente, em vez de tratar todos os anos como igualmente representativos.

4.2 Comparação entre reservas, previsão e políticas de margem

A primeira comparação quantitativa foi realizada entre o planejamento atual baseado exclusivamente em reservas, o modelo preditivo sem margem e políticas de margem previamente testadas. Essa comparação permite observar não apenas a redução do erro preditivo, mas também os efeitos operacionais de cada alternativa sobre sobra, falta e nível de atendimento. A Tabela 2 sintetiza esses resultados.

Tabela 2 - Comparação entre reservas, previsão e políticas anteriores

Abordagem	MAE	RMSE	WAPE (%)	Sobra média	Falta média	Dias com falta (%)	Atendimento (%)
Planejamento atual: reservas	30,92	37,79	23,43	3,65	27,26	83,64	79,34
ExtraTrees sem margem	18,46	24,78	13,99	8,26	10,20	58,18	92,27
Politica contextual	18,21	24,59	13,80	10,85	7,37	43,64	94,42
Margem conservadora	25,90	33,44	19,63	24,35	1,55	15,45	98,82

A Tabela 2 mostra que o planejamento baseado apenas em reservas apresentou maior erro e menor nível de atendimento entre as alternativas comparadas, com MAE de 30,92 refeições, RMSE de 37,79 e WAPE de 23,43%. A incorporação de modelos preditivos e políticas de margem reduziu o erro e melhorou o atendimento, com destaque para a política contextual, que reduziu o MAE para 18,21, o RMSE para 24,59 e o WAPE para 13,80%, elevando o nível de atendimento para 94,42%. Entretanto, os resultados também evidenciam um trade-off operacional: à medida que a falta média diminui e o atendimento aumenta, a sobra média tende a crescer. Por isso, a escolha da política não deve considerar apenas erro estatístico, mas também o equilíbrio entre atendimento e desperdício.

4.3 Estratégias adaptativas e recalibração da margem

Após a comparação inicial, foi avaliada uma política adaptativa recalibrada sobre os modelos com melhor desempenho recente. Essa etapa buscou verificar se a margem de segurança poderia responder melhor às diferenças de comportamento entre os anos, evitando uma margem fixa única para todos os contextos. A Tabela 3 compara o planejamento baseado em reservas, a política contextual anterior e a política adaptativa recalibrada.

Tabela 3 - Comparação da política adaptativa recalibrada com o planejamento por reservas e a política contextual

Política	MAE	RMSE	WAPE (%)	Sobra média	Falta média	Dias com falta (%)	Atendimento (%)
Planejamento atual: reservas	30,92	37,79	23,43	3,65	27,26	83,64	79,34
Política contextual	18,21	24,59	13,80	10,85	7,37	43,64	94,42
Contextual por semana e faixa	17,60	24,01	13,34	23,72	2,01	12,73	98,86

A Tabela 3 indica que a política adaptativa recalibrada apresentou o menor MAE, RMSE e WAPE entre as alternativas avaliadas, além de reduzir expressivamente a falta média e a proporção de dias com falta. A melhor política combinou margem por dia da semana e

faixa de previsão, usando o quantil 70 do resíduo positivo, alcançando MAE de 17,60, RMSE de 24,01, WAPE de 13,34% e nível de atendimento de 98,86%. O ganho operacional, contudo, veio acompanhado de aumento da sobra média para 23,72 refeições por dia, o que confirma que a política adotou perfil mais conservador para evitar falta de refeições. Esse resultado reforça que a margem de segurança deve ser entendida como uma decisão gerencial calibrável, e não como simples acréscimo fixo à previsão.

A recalibração da margem sobre o modelo adaptativo melhorou simultaneamente as métricas preditivas e operacionais. A melhor política encontrada combinou margem por dia da semana e faixa de previsão, usando o quantil 70 do resíduo positivo. Ela reduziu o MAE para 17,60, o RMSE para 24,01 e o WAPE para 13,34%, com atendimento de 98,86% e queda da falta média para 2,01 refeições por dia.

O ganho operacional, contudo, veio acompanhado de aumento da sobra média para 23,72 refeições por dia. Esse resultado não deve ser interpretado apenas como melhoria absoluta, mas como uma alternativa de decisão para contextos em que a falta de refeições possui custo maior que a sobra. A separação entre previsão e política de margem permite ajustar o perfil de risco conforme a prioridade gerencial.

4.4 Implicações para a Engenharia de Produção

Os resultados demonstram que o problema não se resume à escolha de um algoritmo preditivo. A contribuição para a Engenharia de Produção está na construção de um artefato integrado de planejamento: dados auditáveis, engenharia de atributos, validação temporal, métricas preditivas e política operacional. Essa integração conecta ciência de dados a decisões de produção, compras e atendimento.

Do ponto de vista da sustentabilidade, o artefato apoia a redução potencial de desperdício ao alinhar produção planejada e consumo real observado. Ao mesmo tempo, preserva a perspectiva de nível de serviço, pois a redução de sobras não pode comprometer o atendimento aos estudantes. Essa dupla preocupação aproxima o estudo dos ODS 2 e 12, ao tratar segurança alimentar, eficiência operacional e consumo responsável em ambiente institucional.

5. Conclusão

Este artigo apresentou o desenvolvimento e a avaliação de um artefato de apoio ao planejamento da produção de refeições em restaurante escolar. A partir de dados de reservas, consumo, cardápio, calendário e clima, foi construído um fluxo em camadas capaz de gerar bases analíticas, treinar modelos preditivos e avaliar políticas de margem de segurança.

Os resultados indicaram que o planejamento baseado exclusivamente em reservas tornou-se insuficiente nos anos mais recentes, principalmente em 2024 e 2025. Modelos adaptativos com ponderação por recência e janelas temporais melhoraram a previsão, e a recalibração da margem reduziu a falta média e elevou o nível de atendimento. O melhor resultado operacional apresentou MAE de 17,60, RMSE de 24,01, WAPE de 13,34% e atendimento de 98,86%.

Como limitação, o estudo depende da qualidade dos registros administrativos e de consumo manual, além de estar restrito a uma unidade escolar. Também há trade-off entre reduzir faltas e ampliar sobras, de modo que a política final deve ser escolhida conforme custo operacional e prioridade gerencial. Trabalhos futuros podem testar atualização incremental, novas variáveis contextuais, avaliação econômica real e aplicação em outras unidades de alimentação institucional.

Referências

CHAI, T.; DRAXLER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature. Geoscientific Model Development, v. 7, n. 3, p. 1247-1250, 2014.

GREGOR, S.; HEVNER, A. R. Positioning and presenting design science research for maximum impact. MIS Quarterly, v. 37, n. 2, p. 337-355, 2013.

HEVNER, A. R.; MARCH, S. T.; PARK, J.; RAM, S. Design science in information systems research. MIS Quarterly, v. 28, n. 1, p. 75-105, 2004.

KIM, S.; GU, N.; MOON, J.; KIM, K.; HWANG, Y.; LEE, K. Comparative analysis of model performance for predicting the customer of cafeteria using unstructured data. Communications for Statistical Applications and Methods, v. 30, n. 5, p. 485-499, 2023.

MALEFORS, C. Food waste reduction in the public catering sector. Doctoral thesis, Swedish University of Agricultural Sciences, 2022.

PEFFERS, K.; TUUNANEN, T.; ROTHENBERGER, M. A.; CHATTERJEE, S. A design science research methodology for information systems research. Journal of Management Information Systems, v. 24, n. 3, p. 45-77, 2007.

RODRIGUES, M.; MIGUÉIS, V.; FREITAS, S.; MACHADO, T. Machine learning models for short-term demand forecasting in food catering services: a solution to reduce food waste. Journal of Cleaner Production, v. 435, 140265, 2024.

TRIPATHI, S.; MUHR, D.; BRUNNER, M.; JODLBAUER, H.; DEHMER, M.; EMMERT-STREIB, F. Ensuring the robustness and reliability of data-driven knowledge discovery models in production and manufacturing. Frontiers in Artificial Intelligence, v. 4, 576892, 2021.

TURKER, G. F. Reducing food waste in campus dining: a data-driven approach to demand prediction and sustainability. Sustainability, v. 17, n. 2, 379, 2025.

UNITED NATIONS. Transforming our world: the 2030 Agenda for Sustainable Development. New York: United Nations, 2015.